

eda_gym_exercice_dataset_v1.4

November 6, 2025

1 Gym_Exercise_Dataset.csv

1.1 Chargement et inspection initiale

1.1.1 Objectif

Vérifier que le fichier `Gym_Exercise_Dataset.csv` est correctement chargé et obtenir une vue d'ensemble : - dimensions du jeu de données (nombre de lignes et de colonnes), - typage des variables (numériques, catégorielles, textuelles), - détection des valeurs manquantes et doublons, - cohérence générale du corpus avant l'analyse statistique.

Cette étape permet de valider la structure et la qualité du jeu de données avant toute exploration descriptive ou visuelle.

1.1.2 Interprétation attendue

- Le dataset doit contenir une liste d'exercices accompagnés de leurs descriptions (`Title`, `Desc`) et de métadonnées associées (`Type`, `BodyPart`, `Equipment`, `Level`, `Rating`, `RatingDesc`).
- Les types doivent être correctement identifiés : **textuels** pour les descriptions et catégories, **numériques** pour les éventuelles notes.
- L'absence de valeurs manquantes et de doublons confirmera la fiabilité du corpus.
- Les noms de colonnes doivent être homogènes et cohérents pour permettre les traitements automatiques à venir.

1.1.3 Importation des librairies essentielles

```
[51]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import LogNorm
import textwrap
from matplotlib.ticker import PercentFormatter
import seaborn as sns
import kagglehub

import prince
# from scipy import stats
# from sklearn.preprocessing import StandardScaler
# from sklearn.decomposition import PCA
```

```

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
from pathlib import Path
import sys

root = Path.cwd()          # ex: .../DuckDB/eda/life_style_data
themes_root = None

for p in [root, *root.parents]:    # remonte: life_style_data -> eda -> DuckDB
    ↳-> ...
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence (il doit exister un dossier 'themes/' quelque
        ↳part au-dessus)."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print(" Ajouté au PYTHONPATH :", themes_root)
print(" Contenu de", themes_root, ":", [x.name for x in (themes_root).
    ↳iterdir()])

from themes.train_me import set_trainme_theme

```

Ajouté au PYTHONPATH : c:\Users\fbac\Desktop\Projets\Dev\Projet Alyra\DuckDB
 Contenu de c:\Users\fbac\Desktop\Projets\Dev\Projet Alyra\DuckDB : ['.conda',
 '.vscode', '.~lock.Exploration des données - v1.1.odt#', 'datasets',
 'duckdb.exe', 'eda', 'Exploration des données - v1.0.odt', 'Exploration des
 données - v1.0.pdf', 'Exploration des données - v1.1.odt', 'themes']

1.1.4 Configuration d’affichage pour plus de lisibilité

```

[3]: pd.set_option('display.max_columns', None)
    pd.set_option('display.width', 120)

```

1.1.5 Thème “TrAIIn.me”

Il applique un fond dark propre, une grille discrète, des ticks lisibles, et une palette bleus/cians cohérente.

```
[4]: # =====
# Thème TrAIn.me (Seaborn/Matplotlib)
# =====
# Booléen de contrôle : True = thème TrAIn.me (dark), False = style clair
↪ "ticks"
USE_DARK_THEME = True # modifie ici selon le contexte

# Activer le thème au début du notebook :
palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
↪ use_dark=True)
palette_trainme
```

```
[4]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']
```

1.1.6 Chargement du dataset

```
[5]: # Téléchargement du dataset depuis Kaggle
dataset_path = kagglehub.dataset_download("niharika41298/gym-exercise-data")

# Recherche du fichier CSV dans le dossier téléchargé
csv_files = [f for f in os.listdir(dataset_path) if f.endswith(".csv")]
print("Fichiers trouvés :", csv_files)

# Construction du chemin complet vers le CSV
file_path = os.path.join(dataset_path, csv_files[0])

# Lecture du fichier CSV
df = pd.read_csv(file_path)

# Informations de confirmation
print("Dataset chargé avec succès !")
print(f"Dimensions : {df.shape[0]} lignes et {df.shape[1]} colonnes\n")
```

Warning: Looks like you're using an outdated `kagglehub` version, please consider updating (latest version: 0.3.13)

Fichiers trouvés : ['megaGymDataset.csv']

Dataset chargé avec succès !

Dimensions : 2918 lignes et 9 colonnes

Fichiers trouvés : ['megaGymDataset.csv']

Dataset chargé avec succès !

Dimensions : 2918 lignes et 9 colonnes

1.1.7 Aperçu général des premières lignes

```
[6]: display(df.head())
```

```
      Unnamed: 0      Title
0      0      Partner plank band row  The partner plank band row is an
  abdominal exe... Strength  Abdominals
1      1  Banded crunch isometric hold  The banded crunch isometric hold is
  an exercis... Strength  Abdominals
2      2      FYR Banded Plank Jack  The banded plank jack is a
  variation on the pl... Strength  Abdominals
3      3      Banded crunch  The banded crunch is an exercise
  targeting the... Strength  Abdominals
4      4      Crunch  The crunch is a popular core
  exercise targetin... Strength  Abdominals

      Equipment      Level  Rating  RatingDesc
0      Bands  Intermediate      0.0      NaN
1      Bands  Intermediate      NaN      NaN
2      Bands  Intermediate      NaN      NaN
3      Bands  Intermediate      NaN      NaN
4      Bands  Intermediate      NaN      NaN
```

1.1.8 Informations générales sur le typage et la complétude

```
[7]: df_info = df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2918 entries, 0 to 2917
Data columns (total 9 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Unnamed: 0  2918 non-null  int64
1   Title       2918 non-null  object
2   Desc        1368 non-null  object
3   Type        2918 non-null  object
4   BodyPart    2918 non-null  object
5   Equipment   2886 non-null  object
6   Level       2918 non-null  object
7   Rating      1031 non-null  float64
8   RatingDesc  862 non-null   object
dtypes: float64(1), int64(1), object(7)
memory usage: 205.3+ KB
```

1.1.9 Statistiques descriptives des variables numériques

```
[8]: display(df.describe().T)
```

	count	mean	std	min	25%	50%	75%	max
Unnamed: 0	2918.0	1458.50000	842.498368	0.0	729.25	1458.5	2187.75	2917.0
Rating	1031.0	5.91969	3.584607	0.0	3.00	7.9	8.70	9.6

1.1.10 Analyse des valeurs manquantes et doublons

```
[9]: missing_values = df.isnull().sum().sort_values(ascending=False)
duplicates = df.duplicated().sum()

print("\n--- Valeurs manquantes par colonne (top 10) ---")
display(missing_values.head(10))

print(f"\nNombre total de doublons détectés : {duplicates}")
```

--- Valeurs manquantes par colonne (top 10) ---

```
RatingDesc    2056
Rating        1887
Desc          1550
Equipment      32
Unnamed: 0      0
Title          0
Type           0
BodyPart       0
Level          0
dtype: int64
```

Nombre total de doublons détectés : 0

1.1.11 Liste complète des colonnes disponibles

```
[10]: print("\n--- Liste des colonnes du dataset ---")
print(df.columns.tolist())
```

--- Liste des colonnes du dataset ---

```
['Unnamed: 0', 'Title', 'Desc', 'Type', 'BodyPart', 'Equipment', 'Level',
'Rating', 'RatingDesc']
```

1.2 Statistiques descriptives et distribution des variables

1.2.1 Objectif

Explorer la distribution des variables numériques afin de comprendre la variabilité du dataset, identifier d'éventuelles anomalies et détecter les premiers signaux statistiques utiles.

1.2.2 Interprétation attendue

- Confirmer la cohérence statistique des variables numériques disponibles (souvent **Rating**).
- Vérifier la normalité ou l'asymétrie de la distribution (pics, étalement, queue longue).
- Repérer visuellement d'éventuels **outliers** (notes aberrantes, valeurs hors bornes métier).
- Si une seule variable numérique est présente (ex. **Rating**), ces graphiques servent surtout à juger de la dispersion et de la couverture (taux de valeurs manquantes).

1.2.3 Activation du thème TrAIn.me

```
[11]: if USE_DARK_THEME:
    palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
    ↪ use_dark=True)
else:
    sns.set_style("ticks")           # style clair sobre, axes renforcés
    sns.set_context("talk", font_scale=1.05)
    palette_trainme = sns.color_palette("deep") # palette par défaut sobre
    print(" Style activé : 'ticks' → sobre, axes renforcés (présentation pro)")

# Exemple de vérification :
print("Palette active :", palette_trainme.as_hex() if hasattr(palette_trainme,
    ↪ "as_hex") else palette_trainme)
```

Palette active : ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF',
'#64D8FF']

1.2.4 Statistiques descriptives globales

```
[13]: # On limite aux colonnes numériques utiles (exclut un éventuel index 'Unnamed:
    ↪ 0')
num_df = df.select_dtypes(include=[np.number]).copy()
for col in ["Unnamed: 0", "index", "Id", "ID"]:
    if col in num_df.columns:
        num_df = num_df.drop(columns=[col])

stats = num_df.describe().T
display(stats if not stats.empty else pd.DataFrame({"info": ["Aucune variable
    ↪ numérique exploitable"]}))
```

	count	mean	std	min	25%	50%	75%	max
Rating	1031.0	5.91969	3.584607	0.0	3.0	7.9	8.7	9.6

1.2.5 Distribution des variables clés

```
[14]: # Si liste vide → on tente d'utiliser 'Rating' si présent (souvent la seule
    ↪ numérique pertinente)
num_vars = list(num_df.columns)
if not num_vars and "Rating" in df.columns:
    num_vars = ["Rating"]
```

```

if num_vars:
    n = len(num_vars)
    ncols = 3
    nrows = (n + ncols - 1) // ncols

    plt.figure(figsize=(4*ncols, 3*nrows + 1))
    for i, col in enumerate(num_vars, 1):
        plt.subplot(nrows, ncols, i)
        sns.histplot(df[col].dropna(), bins=30, kde=True,
↪color=palette_trainme[i % len(palette_trainme)])
        plt.title(col, fontsize=11, pad=8)
        plt.xlabel(col)
        plt.ylabel("Fréquence")
    plt.tight_layout()
    plt.show()
else:
    print(" Aucune variable numérique à tracer (vérifie la présence de
↪'Rating').")


```



1.2.6 Boxplots pour repérer les outliers

```
[15]: if num_vars:
    n = len(num_vars)
    ncols = 3
    nrows = (n + ncols - 1) // ncols

    plt.figure(figsize=(4*ncols, 3*nrows + 1))
    for i, col in enumerate(num_vars, 1):
        plt.subplot(nrows, ncols, i)
        sns.boxplot(x=df[col], color=palette_trainme[i % len(palette_trainme)])
        plt.title(col, fontsize=11, pad=8)
        plt.xlabel(col)
    plt.tight_layout()
    plt.show()
else:
    print(" Pas de boxplots affichés (aucune variable numérique).")
```



1.2.7 Statistiques descriptives enrichies

```
[16]: # Sélection des variables numériques pertinentes
num_cols = df.select_dtypes(include="number").columns.tolist()

# Calcul des statistiques enrichies
desc = df[num_cols].describe().T
```



```

desc["missing_%"] = df[num_cols].isna().mean() * 100
desc["zeros_%"]   = (df[num_cols] == 0).mean() * 100
desc["skew"]      = df[num_cols].skew()          # asymétrie
desc["kurt"]      = df[num_cols].kurt()          # aplatissement

# Affichage des 12 variables les plus variables
display(desc.sort_values("std", ascending=False).head(12))

```

	count	mean	std	min	25%	50%	75%	max
↳ missing_%	zeros_%	skew \						
Unnamed: 0	2918.0	1458.50000	842.498368	0.0	729.25	1458.5	2187.75	2917.0
↳ 0.000000	0.034270	0.000000						
Rating	1031.0	5.91969	3.584607	0.0	3.00	7.9	8.70	9.6
↳ 64.667581	8.361892	-0.849343						

	kurt
Unnamed: 0	-1.200000
Rating	-1.009552

1.2.8 Détection rapide d'outliers (IQR)

```

[17]: def iqr_outlier_ratio(s: pd.Series, k: float = 1.5) -> float:
        """Renvoie le pourcentage d'outliers selon la règle IQR."""
        q1, q3 = s.quantile(0.25), s.quantile(0.75)
        iqr = q3 - q1
        if iqr == 0:
            return 0.0
        low, high = q1 - k * iqr, q3 + k * iqr
        return ((s < low) | (s > high)).mean() * 100

# Calcul du taux d'outliers pour chaque variable numérique
outlier_report = pd.Series({c: iqr_outlier_ratio(df[c]) for c in num_cols},
                             name="outliers_%")

# Affichage des 12 variables les plus affectées
display(outlier_report.sort_values(ascending=False).head(12))

```

```

Unnamed: 0    0.0
Rating        0.0
Name: outliers_%, dtype: float64

```

1.2.9 Aperçu corrélations (sous-ensemble lisible)

```

[19]: # subset_for_corr = [
#       c for c in [
#           "Calories_Burned", "BMI", "Age", "Max_BPM", "Avg_BPM",
#           "Session_Duration (hours)", "expected_burn", "cal_balance"
#       ] if c in num_cols

```

```
# ]

# corr = df[subset_for_corr].corr(numeric_only=True)

# plt.figure(figsize=(7, 5))
# sns.heatmap(
#     corr,
#     annot=True, fmt=".2f",
#     square=True, cbar=True,
#     annot_kws={"size": 8} # taille de police ajustée
# )
# plt.title("Corrélations (sous-ensemble)", fontsize=12)
# plt.xticks(fontsize=9, rotation=45, ha="right")
# plt.yticks(fontsize=9)
# plt.tight_layout()
# plt.show()
```

1.3 Visualisation univariée

1.3.1 Objectif

Analyser la distribution individuelle des principales variables **numériques** pour : - détecter les asymétries ou concentrations atypiques, - identifier les profils dominants du dataset, - valider la cohérence des mesures (ex. notes/ratings).

1.3.2 Interprétation attendue

- Les variables numériques disponibles (souvent **Rating**) doivent présenter des distributions cohérentes (plage logique, absence de valeurs aberrantes).
- Une **asymétrie** marquée ou des **pics** inhabituels suggèrent des sous-populations (exercices massivement appréciés ou très peu notés).
- Les **boxplots** aident à repérer d'éventuels **outliers** : ils devront être contrôlés (erreurs, cas réels rares) avant la modélisation.
- Si une seule numérique est présente, la lecture se concentre sur sa **dispersion** et sa **couverture** (taux de valeurs manquantes).

1.3.3 Sélection robuste des variables numériques à visualiser

```
[20]: # On part des colonnes numériques existantes et on exclut les index/id
num_df = df.select_dtypes(include=[np.number]).copy()
for col in ["Unnamed: 0", "index", "Id", "ID"]:
    if col in num_df.columns:
        num_df.drop(columns=[col], inplace=True)

# Variables clés à visualiser (si dispo) : priorité à Rating
preferred_order = ["Rating"] # ajoute ici d'autres colonnes si elles existent_
↪ côté Gym
uni_vars = [c for c in preferred_order if c in num_df.columns]
```

```

# Complète avec d'autres numériques si disponibles
uni_vars += [c for c in num_df.columns if c not in uni_vars]

# Par sécurité : on limite à 9 variables pour un layout 3x3 propre
uni_vars = uni_vars[:9]

print("Variables univariées sélectionnées :", uni_vars if uni_vars else "-")

```

Variables univariées sélectionnées : ['Rating']


1.3.4 Visualisation des distributions univariées (hist + KDE)

```

[21]: if uni_vars:
    n = len(uni_vars)
    ncols = 3
    nrows = (n + ncols - 1) // ncols

    plt.figure(figsize=(15, 10 if n > 6 else 7))
    for i, col in enumerate(uni_vars, 1):
        ax = plt.subplot(nrows, ncols, i)
        sns.histplot(df[col].dropna(), kde=True,
                     color=palette_trainme[i % len(palette_trainme)], bins=30)
        ax.set_title(col, fontsize=11, pad=8)
        ax.set_xlabel("")
        ax.grid(True, alpha=0.2)
    plt.tight_layout()
    plt.show()
else:
    print(" Aucune variable numérique à tracer (vérifie la présence de
    ↪ 'Rating').")

```



1.3.5 Boxplots univariés pour détection visuelle d'outliers


```
[22]: if uni_vars:
    n = len(uni_vars)
    ncols = 3
    nrow = (n + ncols - 1) // ncols

    plt.figure(figsize=(15, 8 if n > 6 else 6))
```

```

for i, col in enumerate(uni_vars, 1):
    ax = plt.subplot(nrows, ncols, i)
    sns.boxplot(x=df[col], color=palette_trainme[i % len(palette_trainme)],
    fliersize=2)
    ax.set_title(col, fontsize=10)
    ax.set_xlabel("")
    ax.grid(True, axis="x", alpha=0.2)
plt.tight_layout()
plt.show()
else:
    print(" Pas de boxplots affichés (aucune variable numérique).")

```



1.4 Visualisation bivariée

1.4.1 Objectif

Étudier les relations entre deux variables à la fois pour identifier : - des différences de distribution de **Rating** selon les catégories (Type, BodyPart, Equipment, Level), - des patterns d'usage (ex. Type BodyPart), - des co-occurrences fortes entre attributs décrivant les exercices.

1.4.2 Interprétation attendue

- **Catégories Rating** : si des écarts nets apparaissent entre niveaux (Level) ou familles d'exercices (Type), ils indiquent des préférences/évaluations différenciées selon la difficulté et la nature du mouvement.
- **Co-occurrences** :
 - Type × BodyPart révèle quelles zones du corps sont le plus souvent ciblées par chaque famille d'exercices.
 - Type × Equipment indique le matériel le plus mobilisé par type d'entraînement (haltères, barres, bandes, aucun).
 - Level × Type met en évidence la distribution de difficulté par type (p.ex. davantage d' "Intermediate" en "Strength").
- **Comptage empilé** : compare la mixité des *Types* à l'intérieur des équipements les plus fréquents (en nombre et en ratio), utile pour des recommandations conditionnées par le matériel disponible.

1.4.3 Relations catégorielles numérique (Rating)

```
[23]: # Vérif présence de Rating
has_rating = "Rating" in df.columns and df["Rating"].notna().any()
cat_cols = [c for c in ["Type", "BodyPart", "Equipment", "Level"] if c in df.
↳ columns]

if has_rating and cat_cols:
    # Boxplots + swarm (ou strip) pour visualiser la dispersion par catégorie
    n = len(cat_cols)
    ncols = 2
    nrows = (n + ncols - 1) // ncols


    plt.figure(figsize=(14, 4*nrows))
    for i, c in enumerate(cat_cols, 1):
        ax = plt.subplot(nrows, ncols, i)
        topk = df[c].value_counts().index[:10] # limiter à top 10 pour↳
        ↳ lisibilité
        sub = df[df[c].isin(topk)].copy()
        order = sub[c].value_counts().index

        sns.boxplot(data=sub, x=c, y="Rating", order=order,
                    color=palette_trainme[i % len(palette_trainme)], ax=ax)
        sns.stripplot(data=sub, x=c, y="Rating", order=order, ax=ax,
                    alpha=0.25, size=3, color="white")
```

```

ax.set_title(f"Rating par {c} (top 10)", fontsize=11)
ax.set_xlabel("")
ax.set_ylabel("Rating")
ax.tick_params(axis='x', rotation=30)
ax.grid(True, axis="y", alpha=0.2)
plt.tight_layout()
plt.show()
else:
    print(" Analyse 'catégorie Rating' non effectuée (colonne 'Rating' ↵
↵absente ou vide).")

```



1.4.4 Co-occurrences entre catégories (crosstab + heatmaps)

```

[27]: def plot_crosstab_heatmaps(
    df,
    pairs,
    top_k=12,
    normalize=None,      # None / "row" / "col" (pourcentages)
    annotate=False,      # True pour afficher les valeurs
    log_color=False,     # True pour mieux voir les faibles valeurs
    figsize=(16, 9),
    title_fontsize=13,
    tick_fontsize=9,
    label_rotation_x=30,
    label_rotation_y=0,
    cbar_shrink=0.85

```

```

):
    """Heatmaps propres et lisibles pour crosstabs."""
    if not pairs:
        print(" Aucune paire de catégories disponible.")
        return

    n = len(pairs)
    ncols = 2
    nrows = (n + ncols - 1) // ncols
    fig, axes = plt.subplots(nrows=nrows, ncols=ncols, figsize=figsize)
    axes = np.atleast_1d(axes).ravel()

    for i, (a, b) in enumerate(pairs):
        ax = axes[i]

        # Top-k pour réduire la cardinalité
        a_top = df[a].value_counts().index[:top_k]
        b_top = df[b].value_counts().index[:top_k]
        sub = df[df[a].isin(a_top) & df[b].isin(b_top)]

        ct = pd.crosstab(sub[a], sub[b])

        # Normalisation optionnelle en pourcentages
        if normalize in {"row", "col"}:
            axis = 1 if normalize == "row" else 0
            ct = (ct.div(ct.sum(axis=axis).replace(0, np.nan), axis=1-axis) *
↪100).round(1)

        # Palette & échelle adaptées au dark
        heatmap_kwargs = dict(
            cmap="crest",
            linewidths=0.4,
            linecolor="grey",
            cbar_kws={"shrink": cbar_shrink},
            square=False
        )

        if log_color and normalize is None:
            # Log uniquement pour les comptes bruts (pas en %)
            heatmap_kwargs["norm"] = LogNorm(vmin=max(ct.replace(0, np.nan).
↪min().min(), 1e-6),
                                                vmax=ct.max().max())

        # Annotations optionnelles (évite le bruit sur grands tableaux)
        if annotate:
            sns.heatmap(ct, ax=ax, **heatmap_kwargs, annot=True, fmt=".1f" if
↪normalize else "g",
                        annot_kws={"fontsize": max(tick_fontsize-1, 7)})

```



```

else:
    sns.heatmap(ct, ax=ax, **heatmap_kwargs)

    ax.set_title(f"Co-occurrences {a} × {b} (top {top_k})",
    ↪fontsize=title_fontsize, pad=8)
    ax.set_xlabel(b, fontsize=10)
    ax.set_ylabel(a, fontsize=10)

    # Ticks propres
    ax.tick_params(axis="x", labelsz=tick_fontsize,
    ↪rotation=label_rotation_x)
    ax.tick_params(axis="y", labelsz=tick_fontsize,
    ↪rotation=label_rotation_y)
    ax.grid(False)

    # Masquer axes vides si nombre impair
    for j in range(i+1, nrows*ncols):
        fig.delaxes(axes[j])

plt.tight_layout()
plt.show()

# =====
# Sélection des paires & appel
# =====
pairs = []
if {"Type", "BodyPart"}.issubset(df.columns):
    pairs.append(("Type",
    ↪"BodyPart"))
if {"Type", "Equipment"}.issubset(df.columns):
    pairs.append(("Type",
    ↪"Equipment"))
if {"BodyPart", "Equipment"}.issubset(df.columns):
    pairs.append(("BodyPart",
    ↪"Equipment"))
if {"Level", "Type"}.issubset(df.columns):
    pairs.append(("Level",
    ↪"Type"))

# Choix recommandés pour la lisibilité de ta capture :
# - normalize="row" pour lire des ratios par ligne (plus comparables)
# - annotate=False pour éviter la surcharge visuelle
# - log_color=False (inutile en %)
plot_crosstab_heatmaps(
    df,
    pairs=pairs,
    top_k=12,
    normalize="row",      # None pour comptes bruts ; "row" ou "col" pour %
    annotate=False,      # passe à True si tu veux les valeurs dans les cases


```

```

log_color=False,      # True intéressant si comptes bruts très déséquilibrés
figsize=(16, 10),
title_fontsize=14,
tick_fontsize=10,
label_rotation_x=40, # améliore la lecture en x
label_rotation_y=0,
cbar_shrink=0.8

```

)



1.4.5 Comptage empilé (stacked) : Type au sein du top Equipment

```

[25]: if {"Equipment", "Type"}.issubset(df.columns):
    top_eq = df["Equipment"].value_counts().index[:8]
    sub = df[df["Equipment"].isin(top_eq)].copy()
    tbl = (sub.groupby(["Equipment", "Type"])
           .size()
           .unstack(fill_value=0)
           .sort_index(ascending=True))
    # Normalisation pour ratios (optionnel)
    tbl_ratio = (tbl.T / tbl.T.sum()).T

    # Affichage stacked bar (comptes)
    ax = tbl.plot(kind="bar", stacked=True, figsize=(12, 6), alpha=0.9)
    ax.set_title("Répartition des Types au sein du top 8 Equipment (comptes)")


```


```

ax.set_xlabel("Equipment"); ax.set_ylabel("Nombre")
ax.grid(True, axis="y", alpha=0.2)
plt.legend(title="Type", bbox_to_anchor=(1.02, 1), loc="upper left")
plt.tight_layout()
plt.show()

# Affichage stacked bar (ratios)
ax = tbl_ratio.plot(kind="bar", stacked=True, figsize=(12, 6), alpha=0.9)
ax.set_title("Répartition des Types au sein du top 8 Equipment (ratios)")
ax.set_xlabel("Equipment"); ax.set_ylabel("Part (%)")
ax.grid(True, axis="y", alpha=0.2)
plt.legend(title="Type", bbox_to_anchor=(1.02, 1), loc="upper left")
plt.tight_layout()
plt.show()

```





1.5 Analyse multivariée (ACM)

1.5.1 Objectif

Explorer la structure globale du dataset en combinant les variables **catégorielles** afin : - d'identifier les proximités entre modalités (Type, BodyPart, Equipment, Level), - de visualiser des **regroupements d'exercices** selon leurs caractéristiques, - et de dégager les **axes principaux** qui structurent le corpus.

1.5.2 Interprétation attendue

- Les deux premières dimensions expliquent en général **40–60 % de l'inertie totale**, suffisante pour interpréter les grands axes.
- **Dimension 1 (Dim 1)** oppose souvent les exercices de **renforcement musculaire** (“Strength”, “Powerlifting”) aux exercices de **souplesse ou cardio**.
- **Dimension 2 (Dim 2)** discrimine plutôt les niveaux (Beginner vs Advanced) ou les équipements (Body Only vs Dumbbell/Machine).
- Les modalités proches sur le plan factoriel sont souvent **associées dans les mêmes exercices**.
- Ce plan révèle des **profils types d'exercices** :
 - *Strength / Dumbbell / Intermediate / Upper Body*
 - *Stretching / Body Only / Beginner / Full Body*
- Ces regroupements constituent une base solide pour la création de **profils d'entraînement recommandés** ou de **systèmes de recommandation IA**.

1.5.3 Préparation des données pour l'Analyse des Correspondances Multiples (ACM)

```
[29]: import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

# Sélection des variables qualitatives principales
cat_cols = [c for c in ["Type", "BodyPart", "Equipment", "Level"] if c in df.
             ↪columns]
assert cat_cols, "Aucune variable catégorielle disponible pour l'ACM."

# Copie du sous-ensemble
df_acm = df[cat_cols].dropna().copy()

# Réduction de cardinalité : regroupement des classes rares sous 'Other'
def simplify_categories(s, top_k=12):
    vc = s.value_counts(dropna=False)
    keep = set(vc.index[:top_k])
    return s.where(s.isin(keep), other="Other")

for c in cat_cols:
    df_acm[c] = simplify_categories(df_acm[c].astype(str), top_k=12)

print(f"Variables retenues pour l'ACM : {cat_cols}")
for c in cat_cols:
    print(f"- {c}: {df_acm[c].nunique()} modalités après simplification.")
```

Variables retenues pour l'ACM : ['Type', 'BodyPart', 'Equipment', 'Level']
- Type: 7 modalités après simplification.
- BodyPart: 13 modalités après simplification.
- Equipment: 12 modalités après simplification.
- Level: 3 modalités après simplification.

1.5.4 Analyse des Correspondances Multiples (MCA)

```
[34]: prince.__version__
```

```
[34]: '0.16.0'
```

```
[35]: # --- Fit ACM (engine explicite) ---
mca = prince.MCA(
    n_components=3,
    n_iter=10,
    copy=True,
    check_input=True,
    engine="sklearn", # exigé par prince>=0.16
    random_state=42
).fit(df_acm)
```

```

X_mca = mca.transform(df_acm) # coords individus (Dim1, Dim2, Dim3, ...)

# --- Récupération robuste de l'inertie expliquée ---
def explained_inertia_percent(mca_obj):
    # 1) Certains prince exposent une propriété
    if hasattr(mca_obj, "explained_inertia_"):
        val = getattr(mca_obj, "explained_inertia_")
        # Peut être une liste/ndarray... ou une méthode (rare)
        if callable(val):
            vals = np.array(val())
        else:
            vals = np.array(val)
        return vals * 100.0

    # 2) D'autres exposent eigenvalues_ (valeurs propres) + normalisation
    if hasattr(mca_obj, "eigenvalues_"):
        eig = np.array(mca_obj.eigenvalues_)
        eig = eig[~np.isnan(eig)] # sécurité
        if eig.sum() > 0:
            return (eig / eig.sum()) * 100.0

    # 3) Fallback (aucune info exploitable)
    return np.array([])

explained = explained_inertia_percent(mca)
if explained.size:
    print(f"Variance expliquée par les 3 premières dimensions : {explained[:3].sum():.2f}%")
else:
    print(" Impossible de récupérer l'inertie expliquée (API prince_ inhabituelle).")

```

Variance expliquée par les 3 premières dimensions : 100.00%

1.5.5 Variance expliquée par dimension

```

[39]: dims = min(3, len(explained)) if explained.size else 0
if dims:
    plt.figure(figsize=(6,4))
    sns.barplot(x=[f"Dim{i+1}" for i in range(dims)], y=explained[:dims],
        palette=palette_trainme)
    plt.title("Variance expliquée par dimension (%)", fontsize=12)
    plt.ylabel("Variance (%)")
    plt.xlabel("Dimension factorielle")
    plt.ylim(0, max(10, float(explained[:dims].max()) + 5))
    plt.grid(True, axis="y", alpha=0.3)

```

```
plt.tight_layout()
plt.show()
else:
    print(" Pas de graphique de variance (inertie indisponible).")
```

C:\Users\fbac\AppData\Local\Temp\ipykernel_20616\3019530282.py:4:


FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `x` variable to `hue` and set `legend=False` for the same effect.

```
sns.barplot(x=[f"Dim{i+1}" for i in range(dims)], y=explained[:dims],
palette=palette_trainme)
```

C:\Users\fbac\AppData\Local\Temp\ipykernel_20616\3019530282.py:4: UserWarning:
The palette list has more values (6) than needed (3), which may not be intended.

```
sns.barplot(x=[f"Dim{i+1}" for i in range(dims)], y=explained[:dims],
palette=palette_trainme)
```




1.5.6 Visualisation factorielle des individus (Dim 1 & 2)

```
[40]: if X_mca.shape[1] >= 2:
plt.figure(figsize=(7,6))
sns.scatterplot(x=X_mca.iloc[:,0], y=X_mca.iloc[:,1],
s=10, alpha=0.6, color=palette_trainme[2])
```

```

lab_x = f"Dim 1 ({explained[0]:.1f}% inertie)" if explained.size>=1 else
↳ "Dim 1"
lab_y = f"Dim 2 ({explained[1]:.1f}% inertie)" if explained.size>=2 else
↳ "Dim 2"
plt.xlabel(lab_x); plt.ylabel(lab_y)
plt.title("Projection ACM - individus (Dim 1 × Dim 2)", fontsize=12)
plt.grid(True, alpha=0.3)
plt.tight_layout()
plt.show()
else:
    print(" Moins de 2 dimensions disponibles pour la projection des individus.
↳ ")

```



1.5.7 Visualisation des modalités (categories)

```
[43]: # Récupération des % d'inertie (si dispo) pour les labels d'axes
def _get_explained_pct(mca_obj):
    try:
        vals = mca_obj.explained_inertia_
        if callable(vals): vals = vals()
        return np.array(vals) * 100.0
    except Exception:
        try:
            eig = np.array(mca_obj.eigenvalues_)
            eig = eig[~np.isnan(eig)]
            return (eig / eig.sum()) * 100.0 if eig.sum() > 0 else np.array([])
        except Exception:
            return np.array([])

exp = _get_explained_pct(mca)

# Coordonnées des modalités (colonnes)
cols = mca.column_coordinates(df_acm) # index = "colonne_modalité"
# Coordonnées des individus (lignes) - optionnel
try:
    rows = mca.row_coordinates(df_acm)
except Exception:
    rows = None

# ----- Plot des modalités uniquement (clair et lisible) -----
plt.figure(figsize=(8, 7))
ax = plt.gca()

sns.scatterplot(x=cols[0], y=cols[1], s=50, color=palette_trainme[2],
               ↪edgecolor="none", ax=ax)

# Annotations propres des modalités
for label, (x, y) in cols[[0, 1]].iterrows():
    ax.text(x, y, str(label), fontsize=9, ha="left", va="center")

xl = f"Dim 1 ({exp[0]:.1f}% inertie)" if exp.size >= 1 else "Dim 1"
yl = f"Dim 2 ({exp[1]:.1f}% inertie)" if exp.size >= 2 else "Dim 2"
ax.set_xlabel(xl); ax.set_ylabel(yl)
ax.set_title("Projection ACM - modalités (Dim 1 × Dim 2)", fontsize=12)
ax.axhline(0, color="grey", lw=0.8, alpha=0.5); ax.axvline(0, color="grey",
               ↪lw=0.8, alpha=0.5)
ax.grid(True, alpha=0.25)
plt.tight_layout()
plt.show()
```

```


# ----- Variante avec individus (en arrière-plan), optionnelle -----
if rows is not None and rows.shape[1] >= 2:
    plt.figure(figsize=(8, 7))
    ax = plt.gca()


    # Individus en arrière-plan
    sns.scatterplot(x=rows[0], y=rows[1], s=8, alpha=0.25, color="grey",
↳edgecolor="none", ax=ax, label="Individus")

    # Modalités au premier plan
    sns.scatterplot(x=cols[0], y=cols[1], s=55, color=palette_trainme[3],
↳edgecolor="none", ax=ax, label="Modalités")
    for label, (x, y) in cols[[0, 1]].iterrows():
        ax.text(x, y, str(label), fontsize=9, ha="left", va="center")

    xl = f"Dim 1 ({exp[0]:.1f}% inertie)" if exp.size >= 1 else "Dim 1"
    yl = f"Dim 2 ({exp[1]:.1f}% inertie)" if exp.size >= 2 else "Dim 2"
    ax.set_xlabel(xl); ax.set_ylabel(yl)
    ax.set_title("Projection ACM - individus + modalités (Dim 1 × Dim 2)",
↳fontsize=12)
    ax.axhline(0, color="grey", lw=0.8, alpha=0.5); ax.axvline(0, color="grey",
↳lw=0.8, alpha=0.5)
    ax.legend(loc="best", frameon=False)
    ax.grid(True, alpha=0.25)
    plt.tight_layout()
    plt.show()

```





1.5.8 Contributions des modalités aux axes principaux

```
[44]: # Récupération des contributions colonnes/modalités
try:
    contrib = mca.column_contributions_ # nouvelle propriété (DataFrame)
except AttributeError:
    raise AttributeError("La propriété 'column_contributions_' est absente de cet objet MCA (vérifie ta version de prince).")

# Vérification du format
display(contrib.head())

# Top 10 des modalités les plus contributrices sur la première dimension
if 0 in contrib.columns:
    contrib["Dim1_abs"] = contrib[0].abs()
    top_contrib = contrib.sort_values("Dim1_abs", ascending=False).head(10)
    display(top_contrib)
```

```

else:
    print(" Aucune dimension 0 trouvée dans les contributions.")

```

	0	1	2
Type__Cardio	0.000578	0.020345	0.010399
Type__Olympic Weightlifting	0.139742	0.001139	0.040711
Type__Plyometrics	0.007167	0.064061	0.059305
Type__Powerlifting	0.098511	0.005291	0.003343
Type__Strength	0.020834	0.014968	0.000858

	0	1	2	Dim1_abs
Level__Beginner	0.218595	0.000249	0.004254	0.218595
Equipment__Barbell	0.161413	0.027161	0.048003	0.161413
Type__Olympic Weightlifting	0.139742	0.001139	0.040711	0.139742
Type__Powerlifting	0.098511	0.005291	0.003343	0.098511
BodyPart__Hamstrings	0.094299	0.008747	0.003953	0.094299
BodyPart__Abdominals	0.068908	0.049744	0.006141	0.068908
Level__Intermediate	0.040516	0.000093	0.000177	0.040516
Equipment__Body Only	0.035389	0.155677	0.000241	0.035389
Type__Strongman	0.025193	0.007095	0.000500	0.025193
Type__Strength	0.020834	0.014968	0.000858	0.020834

```

[52]: # Fallback palette si besoin
try:
    _ = palette_trainme
except NameError:
    sns.set_style("ticks"); sns.set_context("talk", font_scale=1.05)
    palette_trainme = sns.color_palette("deep")

contrib = mca.column_contributions_
assert 0 in contrib.columns, "La dimension 0 (Dim 1) est absente de_
↳column_contributions_."

dfc = contrib.copy()
dfc["Dim1_abs"] = dfc[0].abs()

# Index → var/mod (gère MultiIndex et index simples)
if isinstance(dfc.index, pd.MultiIndex):
    dfc = dfc.reset_index().rename(columns={"level_0": "var", "level_1": "mod"})
else:
    idx = dfc.index.astype(str)
    parts = pd.DataFrame(idx.str.split(r"__|_", n=1).tolist(), columns=["var",
↳"mod"])
    parts["var"] = parts["var"].fillna("")
    # Patch: fournir une Series alignée à fillna
    idx_series = pd.Series(idx, index=parts.index)
    parts["mod"] = parts["mod"].fillna(idx_series) # ← corrige le_
↳TypeError

```

```

dfc = pd.concat([dfc.reset_index(drop=True), parts], axis=1)

# Labels compacts (wrap si trop long)
def make_label(v, m, width=28):
    lab = f"{str(v).strip()} - {str(m).strip()}"
    return "\n".join(textwrap.wrap(lab, width=width)) if len(lab) > width else
    ↪lab

dfc["label"] = [make_label(v, m) for v, m in zip(dfc["var"], dfc["mod"])]

# Top 10
top_contrib = dfc.sort_values("Dim1_abs", ascending=False).head(10).copy()

# % si 0-1, sinon absolu
is_prop = top_contrib["Dim1_abs"].max() <= 1.0
top_contrib["plot_value"] = top_contrib["Dim1_abs"] * (100.0 if is_prop else 1.
    ↪0)
x_label = "Contribution (%)" if is_prop else "Contribution (abs.)"

# Palette par variable
vars_unique = top_contrib["var"].unique().tolist()
palette_map = {v: palette_trainme[i % len(palette_trainme)] for i, v in
    ↪enumerate(vars_unique)}
bar_colors = top_contrib["var"].map(palette_map)

# Ordre: petit → grand pour afficher le plus grand en haut
order_y = top_contrib.sort_values("plot_value")["label"]

plt.figure(figsize=(10, 6))
# seaborn v0.14+: éviter le warning "palette sans hue" → utiliser color=None
    ↪+ palette via list colors
ax = sns.barplot(
    data=top_contrib,
    x="plot_value",
    y="label",
    order=order_y,
    palette=bar_colors.tolist() # passe explicitement une liste de couleurs
)

# Annotations intelligentes
xmax = ax.get_xlim()[1]
for y, val in zip(ax.get_yticks(), top_contrib.set_index("label").loc[order_y,
    ↪"plot_value"]):
    txt = f"{val:.1f}%" if is_prop else f"{val:.3f}"
    if val > 0.18 * xmax:
        ax.text(val - 0.01 * xmax, y, txt, va="center", ha="right",
            ↪fontsize=10, color="white")

```

```

else:
    ax.text(val + 0.01 * xmax, y, txt, va="center", ha="left", fontsize=10)

ax.set_title("Top 10 modalités contributrices à la Dim 1", fontsize=13, pad=10)
ax.set_xlabel(x_label); ax.set_ylabel("")
if is_prop:
    ax.xaxis.set_major_formatter(PercentFormatter(100))
ax.grid(True, axis="x", alpha=0.25)
plt.tight_layout()
plt.show()

```

C:\Users\fbac\AppData\Local\Temp\ipykernel_20616\2706044700.py:51:

FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. Assign the `y` variable to `hue` and set `legend=False` for the same effect.

```
ax = sns.barplot(
```

