

eda_gym_exercises_dataset_v1.0

November 18, 2025

1 EDA – Gym Exercises Dataset

1.1 Objectif

Vérifier que le fichier `gym_exercises_dataset.csv` est correctement chargé et obtenir une vue d'ensemble :

- dimensions du jeu de données (nombre de lignes et de colonnes) ;
- typage des variables (champs textuels, listes de muscles, attributs techniques) ;
- premières observations sur les valeurs manquantes et la présence éventuelle de doublons ;
- cohérence générale du corpus avant analyse statistique et préparation NLP.

1.2 Interprétation attendue

À partir de cette première inspection, il s'agira de commenter :

- la taille globale du dataset (nombre de lignes / colonnes) ;
- la nature des variables (descriptifs textuels, attributs biomécaniques, catégories d'équipements) ;
- la présence éventuelle de valeurs manquantes ou de champs textuels incomplets ;
- l'existence (ou non) de doublons dans les données brutes ;
- la cohérence générale des premières lignes (valeurs lisibles, descriptions complètes, muscles cohérents).

Cette interprétation sert de point de départ pour juger de la qualité du corpus et préparer les étapes suivantes : nettoyage, normalisation textuelle et structuration pour le traitement NLP du projet TrAIn.me.

1.3 Configuration notebook

1.3.1 Importation des librairies essentielles

```
[1]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import kagglehub
import prince

from pathlib import Path
```

```

import sys

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from scipy import stats

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
root = Path.cwd() # ex : .../train.me/src/notebooks/eda/health_fitness_dataset
themes_root = None

for p in [root, *root.parents]:
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence : il doit exister un dossier 'themes/' quelque
↳part au-dessus."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print(" Ajouté au PYTHONPATH :", themes_root)
print(" Contenu de", themes_root, ":", [x.name for x in themes_root.iterdir()])

from themes.theme_train_me import set_trainme_theme

```

```

c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\.conda\Lib\site-
packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
    from .autonotebook import tqdm as notebook_tqdm

Ajouté au PYTHONPATH :
c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks
Contenu de c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks :
['eda', 'model_training', 'preprocessing', 'themes', '__init__.py']

```

Configuration d'affichage et thème TrAIn.me

```

[2]: # Options d'affichage pour les tableaux
pd.set_option("display.max_columns", None)
pd.set_option("display.width", 120)

# =====

```

```
# Thème TrAIIn.me (Seaborn/Matplotlib)
# =====
USE_DARK_THEME = True # bascule possible vers un thème clair si besoin

palette_trainme = set_trainme_theme(
    context="talk",
    font_scale=1.05,
    use_dark=USE_DARK_THEME
)

palette_trainme
```

[2]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']

1.3.2 Activation du thème TrAIIn.me

```
[3]: if USE_DARK_THEME:
    palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
    ↪ use_dark=True)
else:
    sns.set_style("ticks") # style clair sobre, axes renforcés
    sns.set_context("talk", font_scale=1.05)
    palette_trainme = sns.color_palette("deep") # palette par défaut sobre
    print(" Style activé : 'ticks' → sobre, axes renforcés (présentation pro)")

# Exemple de vérification :
print("Palette active :", palette_trainme.as_hex() if hasattr(palette_trainme,
    ↪ "as_hex") else palette_trainme)
```

Palette active : ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']

1.3.3 3.4.1. Chargement et inspection initiale

Cette section vise à charger le fichier `gym_exercises_dataset.csv`, vérifier ses dimensions et obtenir un premier aperçu des données brutes. Elle reprend la même démarche que pour les autres EDA du projet : contrôle du chargement, visualisation des premières lignes, statistiques descriptives de base, analyse des valeurs manquantes et des doublons, puis liste complète des colonnes disponibles.

Chargement du dataset `gym_exercises_dataset.csv`

```
[4]: # Téléchargement du dataset depuis Kaggle
dataset_path = kagglehub.dataset_download("rishitmurarka/gym-exercises-dataset")

# Recherche du fichier CSV dans le dossier téléchargé
csv_files = [f for f in os.listdir(dataset_path) if f.endswith(".csv")]
print("Fichiers trouvés :", csv_files)

# Construction du chemin complet vers le CSV
```

```

file_path = os.path.join(dataset_path, csv_files[0])

# Lecture du fichier CSV
df = pd.read_csv(file_path)

# Informations de confirmation
print("Dataset chargé avec succès !")
print(f"Dimensions : {df.shape[0]} lignes et {df.shape[1]} colonnes\n")

```

Downloading from
https://www.kaggle.com/api/v1/datasets/download/rishitmurarka/gym-exercises-dataset?dataset_version_number=1...
 100%| | 48.1k/48.1k [00:00<00:00, 574kB/s]
 Extracting files...
 Fichiers trouvés : ['gym_exercise_dataset.csv', 'stretch_exercise_dataset.csv']
 Dataset chargé avec succès !
 Dimensions : 617 lignes et 17 colonnes

Aperçu des premières lignes

[5]: df.head(10)

[5]:

	Exercise Name	Equipment Variation	Utility
Mechanics	Force \		
0	Neck Flexion	Cable	No Basic or Auxiliary
Isolated	Pull		
1	Neck Flexion	Lever (plate loaded)	No Basic or Auxiliary
Isolated	Pull		
2	Lateral Neck Flexion	Lever (plate loaded)	No Auxiliary
Isolated	Pull		
3	Neck Flexion	Lever (selectorized)	No Basic or Auxiliary
Isolated	Pull		
4	Lateral Neck Flexion	Lever (selectorized)	No Auxiliary
Isolated	Pull		
5	Neck Flexion	Weighted	No Basic or Auxiliary
Isolated	Pull		
6	Lateral Neck Flexion	Weighted	No Auxiliary
Isolated	Pull		
7	Wall Front Neck Bridge	Body Weight	No Basic or Auxiliary
Isolated	Push & Pull		
8	Wall Side Neck Bridge	Body Weight	No Auxiliary
Isolated	Pull		
9	Neck Flexion	Suspended	No Basic or Auxiliary
Isolated	Pull		

Preparation

Execution \

- 0 Sit on bench facing away from middle pulley. P... Move head away from pulley by bending neck for...
- 1 Sit on seat in machine. Position padded lever ... Move head forward by flexing neck until chin t...
- 2 Sit on seat in machine with feet apart . Pos... Move head down to side by laterally flexing ne...
- 3 Sit on seat in machine. Position padded lever ... Move head forward by flexing neck until chin t...
- 4 Sit on seat in machine with feet apart. Positi... Move head down to side by laterally flexing ne...
- 5 Place folded towel on weight plate. Lie supine... Move head up by flexing neck until chin touche...
- 6 Place folded towel on weight plate. Lie on ben... Move head up to side by laterally flexing neck...
- 7 Place small or folded cushioned mat on wall or... Roll down onto forehead until nose touches mat...
- 8 Place small or folded cushioned mat on column ... Push side of head into mat and roll onto top o...
- 9 Place belt or strap around end of suspension t... Increase angle of body by bowing head until ch...

Target_Muscles

Synergist_Muscles \

- | | | |
|---|--|-------|
| 0 | Sternocleidomastoid, | None, |
| 1 | Sternocleidomastoid, | None, |
| 2 | Sternocleidomastoid, Splenius, Erector Spinae, Levator Scapulae, Tr... | |
| 3 | Sternocleidomastoid, | None, |
| 4 | Sternocleidomastoid, Splenius, Erector Spinae, Levator Scapulae, Tr... | |
| 5 | Sternocleidomastoid, | None, |
| 6 | Sternocleidomastoid, Splenius, Erector Spinae, Levator Scapulae, Tr... | |
| 7 | Sternocleidomastoid, Splenius, Trapezius, Upper, Levator Scapulae, ... | |
| 8 | Sternocleidomastoid, Splenius, Trapezius, Upper, Levator Scapulae, ... | |
| 9 | Sternocleidomastoid, Splenius, Trapezius, Upper, Erector Spinae, Ce... | |

Stabilizer_Muscles Antagonist_Muscles

Dynamic_Stabilizer_Muscles Main_muscle \

- | | | |
|-----|---|-----|
| 0 | Rectus Abdominis, Obliques, | NaN |
| NaN | Neck | |
| 1 | Latissimus Dorsi, Deltoid, Posterior, Rhomboid... | NaN |
| NaN | Neck | |
| 2 | Latissimus Dorsi, Pectoralis Major, Sternal, P... | NaN |
| NaN | Neck | |
| 3 | Latissimus Dorsi, Deltoid, Posterior, Rhomboid... | NaN |
| NaN | Neck | |
| 4 | Latissimus Dorsi, Pectoralis Major, Sternal, P... | NaN |

NaN	Neck		
5		Rectus Abdominis, Obliques,	NaN
NaN	Neck		
6		NaN	NaN
NaN	Neck		
7		Rectus Abdominis, Obliques, Quadriceps, Erector Spinae,	
NaN	Neck		
8		Gluteus Medius, Gluteus Minimus,	NaN
NaN	Neck		
9		NaN	NaN
NaN	Neck		

	Difficulty (1-5)	Secondary Muscles	parent_id
0	2	Sternocleidomastoid	NaN
1	2	Sternocleidomastoid	NaN
2	2	Sternocleidomastoid, Levator Scapulae	NaN
3	2	Sternocleidomastoid	NaN
4	2	Sternocleidomastoid, Levator Scapulae	NaN
5	2	Sternocleidomastoid	NaN
6	2	Sternocleidomastoid, Levator Scapulae	NaN
7	3	Sternocleidomastoid, Upper Trapezius	NaN
8	3	Sternocleidomastoid, Upper Trapezius	NaN
9	2	Sternocleidomastoid	NaN

Informations sur le typage, les valeurs manquantes et les doublons

```
[6]: # Typage et complétude globale
df_info = df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 617 entries, 0 to 616
Data columns (total 17 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Exercise Name                        617 non-null    object
1   Equipment                           617 non-null    object
2   Variation                           613 non-null    object
3   Utility                             617 non-null    object
4   Mechanics                           617 non-null    object
5   Force                               617 non-null    object
6   Preparation                         617 non-null    object
7   Execution                           617 non-null    object
8   Target_Muscles                      617 non-null    object
9   Synergist_Muscles                   615 non-null    object
10  Stabilizer_Muscles                   489 non-null    object
11  Antagonist_Muscles                   141 non-null    object
12  Dynamic_Stabilizer_Muscles           265 non-null    object
13  Main_muscle                          617 non-null    object
```

```

14 Difficulty (1-5)          617 non-null    int64
15 Secondary Muscles        616 non-null    object
16 parent_id                161 non-null    float64
dtypes: float64(1), int64(1), object(15)
memory usage: 82.1+ KB

```

1.3.4 Statistiques descriptives des variables numériques

```
[7]: display(df.describe().T)
```

	count	mean	std	min	25%	50%	75%	max
Difficulty (1-5)	617.0	2.737439	0.893215	1.0	2.0	3.0	3.0	5.0
parent_id	161.0	307.248447	158.649536	14.0	181.0	341.0	449.0	615.0

1.3.5 Analyse des valeurs manquantes et doublons

```

[8]: # Comptage des valeurs manquantes par colonne
missing_counts = df.isna().sum().sort_values(ascending=False)

print("\n Valeurs manquantes par colonne (top 20) :")
display(missing_counts.head(20))

# Comptage des doublons ligne à ligne
n_duplicates = df.duplicated().sum()
print(f"\n Nombre de doublons (lignes strictement identiques) : {n_duplicates}")

```

Valeurs manquantes par colonne (top 20) :

Antagonist_Muscles	476
parent_id	456
Dynamic_Stabilizer_Muscles	352
Stabilizer_Muscles	128
Variation	4
Synergist_Muscles	2
Secondary Muscles	1
Difficulty (1-5)	0
Main_muscle	0
Exercise Name	0
Equipment	0
Execution	0
Preparation	0
Force	0
Mechanics	0
Utility	0
Target_Muscles	0

dtype: int64

Nombre de doublons (lignes strictement identiques) : 0

Liste complète des colonnes disponibles

```
[9]: print("\n--- Liste des colonnes du dataset ---")  
     print(df.columns.tolist())
```

```
--- Liste des colonnes du dataset ---  
['Exercise Name', 'Equipment', 'Variation', 'Utility', 'Mechanics', 'Force',  
'Preparation', 'Execution', 'Target_Muscles', 'Synergist_Muscles',  
'Stabilizer_Muscles', 'Antagonist_Muscles', 'Dynamic_Stabilizer_Muscles',  
'Main_muscle', 'Difficulty (1-5)', 'Secondary Muscles', 'parent_id']
```