

eda_gym_exercises_dataset_v1.3

November 18, 2025

1 EDA – Gym Exercises Dataset

1.1 Objectif

Vérifier que le fichier `gym_exercises_dataset.csv` est correctement chargé et obtenir une vue d'ensemble :

- dimensions du jeu de données (nombre de lignes et de colonnes) ;
- typage des variables (champs textuels, listes de muscles, attributs techniques) ;
- premières observations sur les valeurs manquantes et la présence éventuelle de doublons ;
- cohérence générale du corpus avant analyse statistique et préparation NLP.

1.2 Interprétation attendue

À partir de cette première inspection, il s'agira de commenter :

- la taille globale du dataset (nombre de lignes / colonnes) ;
- la nature des variables (descriptifs textuels, attributs biomécaniques, catégories d'équipements) ;
- la présence éventuelle de valeurs manquantes ou de champs textuels incomplets ;
- l'existence (ou non) de doublons dans les données brutes ;
- la cohérence générale des premières lignes (valeurs lisibles, descriptions complètes, muscles cohérents).

Cette interprétation sert de point de départ pour juger de la qualité du corpus et préparer les étapes suivantes : nettoyage, normalisation textuelle et structuration pour le traitement NLP du projet TrAIn.me.

1.3 Configuration notebook

1.3.1 Importation des librairies essentielles

```
[22]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import LogNorm
import seaborn as sns
import kagglehub
import prince
```

```

from pathlib import Path
import sys

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from scipy import stats

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
root = Path.cwd() # ex : .../train.me/src/notebooks/eda/health_fitness_dataset
themes_root = None

for p in [root, *root.parents]:
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence : il doit exister un dossier 'themes/' quelque
↳part au-dessus."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print(" Ajouté au PYTHONPATH :", themes_root)
print(" Contenu de", themes_root, ":", [x.name for x in themes_root.iterdir()])

from themes.theme_train_me import set_trainme_theme

```

Ajouté au PYTHONPATH :

```
c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks
```

Contenu de c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks :

```
['eda', 'model_training', 'preprocessing', 'themes', '__init__.py']
```

Configuration d'affichage et thème TrAIn.me

```

[2]: # Options d'affichage pour les tableaux
pd.set_option("display.max_columns", None)
pd.set_option("display.width", 120)

# =====
# Thème TrAIn.me (Seaborn/Matplotlib)
# =====
USE_DARK_THEME = True # bascule possible vers un thème clair si besoin

```

```
palette_trainme = set_trainme_theme(
    context="talk",
    font_scale=1.05,
    use_dark=USE_DARK_THEME
)

palette_trainme
```

[2]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']

1.3.2 Activation du thème TrAIIn.me

```
[3]: if USE_DARK_THEME:
    palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
    ↪use_dark=True)
else:
    sns.set_style("ticks")           # style clair sobre, axes renforcés
    sns.set_context("talk", font_scale=1.05)
    palette_trainme = sns.color_palette("deep") # palette par défaut sobre
    print(" Style activé : 'ticks' → sobre, axes renforcés (présentation pro)")

# Exemple de vérification :
print("Palette active :", palette_trainme.as_hex() if hasattr(palette_trainme,
    ↪"as_hex") else palette_trainme)
```

Palette active : ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']

1.3.3 3.4.1. Chargement et inspection initiale

Cette section vise à charger le fichier `gym_exercises_dataset.csv`, vérifier ses dimensions et obtenir un premier aperçu des données brutes. Elle reprend la même démarche que pour les autres EDA du projet : contrôle du chargement, visualisation des premières lignes, statistiques descriptives de base, analyse des valeurs manquantes et des doublons, puis liste complète des colonnes disponibles.

Chargement du dataset `gym_exercises_dataset.csv`

```
[4]: # Téléchargement du dataset depuis Kaggle
dataset_path = kagglehub.dataset_download("rishitmurarka/gym-exercises-dataset")

# Recherche du fichier CSV dans le dossier téléchargé
csv_files = [f for f in os.listdir(dataset_path) if f.endswith(".csv")]
print("Fichiers trouvés :", csv_files)

# Construction du chemin complet vers le CSV
file_path = os.path.join(dataset_path, csv_files[0])

# Lecture du fichier CSV
```

```
df = pd.read_csv(file_path)

# Informations de confirmation
print("Dataset chargé avec succès !")
print(f"Dimensions : {df.shape[0]} lignes et {df.shape[1]} colonnes\n")
```

Downloading from
https://www.kaggle.com/api/v1/datasets/download/rishitmurarka/gym-exercises-dataset?dataset_version_number=1...

100%| | 48.1k/48.1k [00:00<00:00, 574kB/s]

Extracting files...

Fichiers trouvés : ['gym_exercise_dataset.csv', 'stretch_exercise_dataset.csv']

Dataset chargé avec succès !

Dimensions : 617 lignes et 17 colonnes

Aperçu des premières lignes

```
[5]: df.head(10)
```

```
[5]:
```

	Exercise Name	Equipment	Variation	Utility
0	Mechanics Force \ Neck Flexion	Cable	No	Basic or Auxiliary
1	Isolated Pull Neck Flexion	Lever (plate loaded)	No	Basic or Auxiliary
2	Isolated Pull Lateral Neck Flexion	Lever (plate loaded)	No	Auxiliary
3	Isolated Pull Neck Flexion	Lever (selectorized)	No	Basic or Auxiliary
4	Isolated Pull Lateral Neck Flexion	Lever (selectorized)	No	Auxiliary
5	Isolated Pull Neck Flexion	Weighted	No	Basic or Auxiliary
6	Isolated Pull Lateral Neck Flexion	Weighted	No	Auxiliary
7	Isolated Push & Pull Wall Front Neck Bridge	Body Weight	No	Basic or Auxiliary
8	Isolated Pull Wall Side Neck Bridge	Body Weight	No	Auxiliary
9	Isolated Pull Neck Flexion	Suspended	No	Basic or Auxiliary

Preparation

Execution \

0 Sit on bench facing away from middle pulley. P... Move head away from pulley

by bending neck for...

- 1 Sit on seat in machine. Position padded lever ... Move head forward by flexing neck until chin t...
- 2 Sit on seat in machine with feet apart . Pos... Move head down to side by laterally flexing ne...
- 3 Sit on seat in machine. Position padded lever ... Move head forward by flexing neck until chin t...
- 4 Sit on seat in machine with feet apart. Positi... Move head down to side by laterally flexing ne...
- 5 Place folded towel on weight plate. Lie supine... Move head up by flexing neck until chin touche...
- 6 Place folded towel on weight plate. Lie on ben... Move head up to side by laterally flexing neck...
- 7 Place small or folded cushioned mat on wall or... Roll down onto forehead until nose touches mat...
- 8 Place small or folded cushioned mat on column ... Push side of head into mat and roll onto top o...
- 9 Place belt or strap around end of suspension t... Increase angle of body by bowing head until ch...

	Target_Muscles	Synergist_Muscles \
0	Sternocleidomastoid,	None,
1	Sternocleidomastoid,	None,
2	Sternocleidomastoid, Splenius, Erector Spinae, Levator Scapulae, Tr...	
3	Sternocleidomastoid,	None,
4	Sternocleidomastoid, Splenius, Erector Spinae, Levator Scapulae, Tr...	
5	Sternocleidomastoid,	None,
6	Sternocleidomastoid, Splenius, Erector Spinae, Levator Scapulae, Tr...	
7	Sternocleidomastoid, Splenius, Trapezius, Upper, Levator Scapulae, ...	
8	Sternocleidomastoid, Splenius, Trapezius, Upper, Levator Scapulae, ...	
9	Sternocleidomastoid, Splenius, Trapezius, Upper, Erector Spinae, Ce...	

	Stabilizer_Muscles	Antagonist_Muscles
Dynamic_Stabilizer_Muscles Main_muscle \		
0	Rectus Abdominis, Obliques,	NaN
NaN	Neck	
1	Latissimus Dorsi, Deltoid, Posterior, Rhomboid...	NaN
NaN	Neck	
2	Latissimus Dorsi, Pectoralis Major, Sternal, P...	NaN
NaN	Neck	
3	Latissimus Dorsi, Deltoid, Posterior, Rhomboid...	NaN
NaN	Neck	
4	Latissimus Dorsi, Pectoralis Major, Sternal, P...	NaN
NaN	Neck	
5	Rectus Abdominis, Obliques,	NaN
NaN	Neck	
6		NaN

NaN	Neck		
7	Rectus Abdominis, Obliques, Quadriceps,	Erector Spinae,	
NaN	Neck		
8	Gluteus Medius, Gluteus Minimus,		NaN
NaN	Neck		
9		NaN	NaN
NaN	Neck		

	Difficulty (1-5)	Secondary Muscles	parent_id
0	2	Sternocleidomastoid	NaN
1	2	Sternocleidomastoid	NaN
2	2	Sternocleidomastoid, Levator Scapulae	NaN
3	2	Sternocleidomastoid	NaN
4	2	Sternocleidomastoid, Levator Scapulae	NaN
5	2	Sternocleidomastoid	NaN
6	2	Sternocleidomastoid, Levator Scapulae	NaN
7	3	Sternocleidomastoid, Upper Trapezius	NaN
8	3	Sternocleidomastoid, Upper Trapezius	NaN
9	2	Sternocleidomastoid	NaN

Informations sur le typage, les valeurs manquantes et les doublons

```
[6]: # Typage et complétude globale
df_info = df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 617 entries, 0 to 616
Data columns (total 17 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Exercise Name                        617 non-null    object
1   Equipment                            617 non-null    object
2   Variation                            613 non-null    object
3   Utility                             617 non-null    object
4   Mechanics                            617 non-null    object
5   Force                               617 non-null    object
6   Preparation                          617 non-null    object
7   Execution                            617 non-null    object
8   Target_Muscles                       617 non-null    object
9   Synergist_Muscles                   615 non-null    object
10  Stabilizer_Muscles                   489 non-null    object
11  Antagonist_Muscles                   141 non-null    object
12  Dynamic_Stabilizer_Muscles           265 non-null    object
13  Main_muscle                          617 non-null    object
14  Difficulty (1-5)                     617 non-null    int64
15  Secondary Muscles                    616 non-null    object
16  parent_id                           161 non-null    float64
dtypes: float64(1), int64(1), object(15)
```

memory usage: 82.1+ KB

1.3.4 Statistiques descriptives des variables numériques

```
[7]: display(df.describe().T)
```

	count	mean	std	min	25%	50%	75%	max
Difficulty (1-5)	617.0	2.737439	0.893215	1.0	2.0	3.0	3.0	5.0
parent_id	161.0	307.248447	158.649536	14.0	181.0	341.0	449.0	615.0

1.3.5 Analyse des valeurs manquantes et doublons

```
[8]: # Comptage des valeurs manquantes par colonne
missing_counts = df.isna().sum().sort_values(ascending=False)

print("\n Valeurs manquantes par colonne (top 20) :")
display(missing_counts.head(20))

# Comptage des doublons ligne à ligne
n_duplicates = df.duplicated().sum()
print(f"\n Nombre de doublons (lignes strictement identiques) : {n_duplicates}")
```

Valeurs manquantes par colonne (top 20) :

Antagonist_Muscles	476
parent_id	456
Dynamic_Stabilizer_Muscles	352
Stabilizer_Muscles	128
Variation	4
Synergist_Muscles	2
Secondary_Muscles	1
Difficulty (1-5)	0
Main_muscle	0
Exercise Name	0
Equipment	0
Execution	0
Preparation	0
Force	0
Mechanics	0
Utility	0
Target_Muscles	0

dtype: int64

Nombre de doublons (lignes strictement identiques) : 0

Liste complète des colonnes disponibles

```
[9]: print("\n--- Liste des colonnes du dataset ---")
      print(df.columns.tolist())
```

```
--- Liste des colonnes du dataset ---
['Exercise Name', 'Equipment', 'Variation', 'Utility', 'Mechanics', 'Force',
'Preparation', 'Execution', 'Target_Muscles', 'Synergist_Muscles',
'Stabilizer_Muscles', 'Antagonist_Muscles', 'Dynamic_Stabilizer_Muscles',
'Main_muscle', 'Difficulty (1-5)', 'Secondary Muscles', 'parent_id']
```

1.4 Statistiques descriptives et distribution des variables

1.4.1 Objectif

Obtenir une vue d'ensemble chiffrée des variables numériques du dataset :

- résumer la distribution des variables disponibles (Difficulty (1-5), parent_id) ;
- repérer les ordres de grandeur, la dispersion et les éventuelles valeurs extrêmes ;
- identifier la répartition des niveaux de difficulté des exercices ;
- préparer l'identification d'outliers et la sélection de variables pertinentes pour la suite de l'analyse.

1.4.2 Interprétation attendue

À l'issue de cette section, l'interprétation devra mettre en évidence :

- la distribution des niveaux de difficulté des exercices (répartition sur l'échelle 1-5) ;
- le rôle de parent_id comme identifiant de regroupement plutôt que comme variable métier ;
- la présence éventuelle de valeurs extrêmes ou atypiques sur les variables numériques ;
- les premières tendances sur la structure du corpus (exercices majoritairement faciles, intermédiaires ou difficiles).

Ces éléments guideront la suite de l'EDA, notamment la détection d'anomalies et la préparation des features pour les futurs modèles NLP et de recommandation.

1.4.3 Statistiques descriptives globales

```
[10]: # --- Colonnes numériques disponibles ---
num_cols = df.select_dtypes(include="number").columns.tolist()
print(f"Variables numériques détectées ({len(num_cols)}) : {num_cols}")

# Statistiques descriptives de base
stats_num = df[num_cols].describe().T
display(stats_num)

# Quelques repères métier
if "Difficulty (1-5)" in df.columns:
    print(f"\nDifficulté moyenne : {df['Difficulty (1-5)'].mean():.2f} / 5")
    print("Répartition des niveaux de difficulté :")
    display(df["Difficulty (1-5)"].value_counts().sort_index())
```


Variables numériques détectées (2) : ['Difficulty (1-5)', 'parent_id']

	count	mean	std	min	25%	50%	75%	max
Difficulty (1-5)	617.0	2.737439	0.893215	1.0	2.0	3.0	3.0	5.0
parent_id	161.0	307.248447	158.649536	14.0	181.0	341.0	449.0	615.0

Difficulté moyenne : 2.74 / 5

Répartition des niveaux de difficulté :

Difficulty (1-5)

1	41
2	209
3	254
4	97
5	16

Name: count, dtype: int64

1.4.4 Distribution des variables clés

```
[11]: # On garde les variables numériques réellement intéressantes
num_vars = [c for c in num_cols if c != "parent_id"] # parent_id = identifiant_
↳ technique
print(f"Variables numériques représentées : {num_vars}")


n = len(num_vars)
if n == 0:
    print(" Aucune variable numérique pertinente à visualiser.")
else:
    n_cols = 2
    n_rows = int(np.ceil(n / n_cols))

    plt.figure(figsize=(5 * n_cols, 4 * n_rows))

    for i, col in enumerate(num_vars, 1):
        plt.subplot(n_rows, n_cols, i)
        sns.histplot(df[col], bins=20, kde=True)
        plt.title(col)
        plt.grid(True, axis="y")

    plt.tight_layout()
    plt.show()
```

Variables numériques représentées : ['Difficulty (1-5)']




1.4.5 Boxplots pour repérer les outliers

```
[12]: if num_vars:
    plt.figure(figsize=(5 * len(num_vars), 4))

    for i, col in enumerate(num_vars, 1):
        plt.subplot(1, len(num_vars), i)
        sns.boxplot(x=df[col])
        plt.title(col)
        plt.grid(True, axis="x")

    plt.tight_layout()
    plt.show()
else:
    print(" Aucun boxplot pertinent à afficher (pas de variable numérique,
    ↪ métier).")
```



1.4.6 Statistiques descriptives enrichies

```
[13]: if num_cols:
    desc = df[num_cols].describe().T
    desc["missing_%"] = df[num_cols].isna().mean() * 100
    desc["zeros_%"] = (df[num_cols] == 0).mean() * 100
    desc["skew"] = df[num_cols].skew()
    desc["kurt"] = df[num_cols].kurt()

    display(desc.sort_values("std", ascending=False))
else:
    print(" Aucune variable numérique disponible pour des statistiques_
    ↪enrichies.")
```

	count	mean	std	min	25%	50%	75%	↪
↪max missing_%	zeros_%	skew \						
parent_id	161.0	307.248447	158.649536	14.0	181.0	341.0	449.0	615.
↪0 73.905997	0.0	-0.197914						
Difficulty (1-5)	617.0	2.737439	0.893215	1.0	2.0	3.0	3.0	5.
↪0 0.000000	0.0	0.197199						
		kurt						
parent_id		-1.036210						
Difficulty (1-5)		-0.175658						

1.4.7 Détection rapide d'outliers (IQR)

```
[14]: iqr_report = {}

for col in num_cols:
    Q1 = df[col].quantile(0.25)
    Q3 = df[col].quantile(0.75)
    IQR = Q3 - Q1

    outliers = df[(df[col] < Q1 - 1.5 * IQR) | (df[col] > Q3 + 1.5 * IQR)]
    iqr_report[col] = len(outliers)


iqr_df = pd.DataFrame.from_dict(iqr_report, orient="index",
    ↪columns=["outliers"])
iqr_df.sort_values("outliers", ascending=False)
```

```
[14]:              outliers
Difficulty (1-5)         16
parent_id                 0
```

1.4.8 Aperçu corrélations (sous-ensemble lisible)

```
[15]: if len(num_cols) >= 2:
    subset_cols = num_cols # très peu de variables numériques ici
    corr = df[subset_cols].corr(numeric_only=True)

    plt.figure(figsize=(5, 4))
    sns.heatmap(
        corr,
        annot=True,
        fmt=".2f",
        square=True,
        cbar=True,
        linewidths=0.5,
    )
    plt.title("Corrélations (variables numériques)", fontsize=12, pad=10)
    plt.tight_layout()
    plt.show()
else:
    print(" Corrélation non pertinente : une seule variable numérique ↪
    ↪disponible.")
```



1.5 Visualisation univariée

1.5.1 Objectif

Compléter les statistiques descriptives par une analyse visuelle des distributions des variables numériques du dataset.

Dans le cas du Gym Exercises Dataset, il s'agit principalement de :

- visualiser la répartition des niveaux de difficulté (Difficulty (1-5)) ;
- vérifier l'éventuelle présence de valeurs extrêmes ou atypiques ;
- confirmer le rôle de parent_id comme identifiant technique plus que comme variable métier continue ;
- préparer les décisions de nettoyage ou de regroupement éventuel pour la suite de l'analyse.

1.5.2 Interprétation attendue

À l'issue de cette section, l'analyse devra :

- décrire la forme de la distribution de Difficulty (1-5) (niveau dominant, éventuel déséquilibre entre exercices faciles et difficiles) ;
- signaler la présence ou non de niveaux très peu représentés ;
- confirmer le caractère peu informatif de parent_id en tant que variable numérique (utilisation structurelle, valeurs dispersées) ;
- identifier visuellement d'éventuels points atypiques qui pourraient justifier un traitement spécifique dans les étapes suivantes.

Ces éléments complètent la lecture purement chiffrée et orientent les choix de préparation des features pour les futurs modèles NLP et de recommandation.

1.5.3 Sélection robuste des variables numériques à visualiser

```
[16]: # --- Sélection des variables numériques pertinentes pour la visualisation
      ↪ univariée ---

num_cols = df.select_dtypes(include=["number"]).columns.tolist()
print("Variables numériques détectées :", num_cols)

# On conserve Difficulty (1-5) comme variable métier principale
# et on laisse parent_id optionnel (identifiant technique de regroupement)
vars_univariate = [c for c in num_cols if c == "Difficulty (1-5)"]

print("Variables retenues pour la visualisation univariée :", vars_univariate)
```

Variables numériques détectées : ['Difficulty (1-5)', 'parent_id']

Variables retenues pour la visualisation univariée : ['Difficulty (1-5)']


1.5.4 Visualisation des distributions univariées (hist + KDE)

```
[17]: if not vars_univariate:
      print(" Aucune variable numérique pertinente à visualiser.")
      else:
          n = len(vars_univariate)
          n_cols = min(3, n)
          n_rows = int(np.ceil(n / n_cols))

          plt.figure(figsize=(5 * n_cols, 4 * n_rows))

          for i, col in enumerate(vars_univariate, start=1):
              plt.subplot(n_rows, n_cols, i)
              sns.histplot(df[col], bins=10, kde=True)
              plt.title(col)
              plt.grid(True, axis="y")

          plt.tight_layout()
          plt.show()
```




1.5.5 Boxplots univariés pour détection visuelle d'outliers

```
[18]: if not vars_univariate:
    print(" Aucun boxplot pertinent à afficher (pas de variable numérique,
    ↳ métier).")
else:
    plt.figure(figsize=(5 * len(vars_univariate), 4))

    for i, col in enumerate(vars_univariate, start=1):
        plt.subplot(1, len(vars_univariate), i)
        sns.boxplot(x=df[col])
        plt.title(col)
        plt.grid(True, axis="x")

    plt.tight_layout()
    plt.show()
```



1.6 3.4.4. Visualisation bivariable

1.6.1 Objectif

Explorer les relations entre la variable numérique de difficulté (*Difficulty (1-5)*) et les principales variables catégorielles du corpus (Equipment, Main_muscle, Utility, etc.).

L'objectif est de :

- comprendre comment la difficulté se répartit selon les types d'équipement et les groupes musculaires ;
- analyser les co-occurrences entre catégories (combinaisons Equipment $\times$ Main_muscle, par exemple) ;
- identifier les types d'exercices les plus représentés au sein des machines les plus utilisées.

Ces éléments permettront de mieux structurer le catalogue d'exercices pour les futurs modèles de recommandation et de NLP.

1.6.2 Interprétation attendue

À l'issue de cette section, l'analyse devra :

- mettre en évidence les équipements associés aux niveaux de difficulté les plus élevés ou les plus faibles ;
- décrire les couples de catégories fréquents (par exemple Equipment $\times$ Main_muscle) et leurs patterns ;
- visualiser la répartition des types d'exercices (Utility) au sein des équipements les plus présents ;

- dégager des pistes sur la manière dont la difficulté se combine avec l'équipement et les groupes musculaires.

Ces observations aideront à concevoir des règles métiers et à orienter le pré-traitement des textes (catégorisation, regroupements, mappings pour le NLP).

1.6.3 Relations catégorielles numérique (Difficulty (1-5))

Dans un premier temps, on observe comment la difficulté moyenne des exercices évolue selon l'équipement utilisé et le muscle principal ciblé.

```
[19]: rating_col = "Difficulty (1-5)"

# --- Difficulté moyenne par équipement ---
equip_rating = (
    df.groupby("Equipment")[rating_col]
    .agg(["count", "mean"])
    .sort_values("mean", ascending=False)
)

display(equip_rating.head(15))

plt.figure(figsize=(10, 5))
top_equip = equip_rating.head(10).index

sns.barplot(
    data=df[df["Equipment"].isin(top_equip)],
    x="Equipment",
    y=rating_col,
    estimator=np.mean,
)
plt.xticks(rotation=45, ha="right")
plt.title("Difficulté moyenne par équipement (Top 10)")
plt.grid(True, axis="y")
plt.tight_layout()
plt.show()

# --- Difficulté par muscle principal (boxplots) ---
plt.figure(figsize=(10, 6))
top_muscles = (
    df["Main_muscle"]
    .value_counts()
    .head(8)
    .index
)


sns.boxplot(
    data=df[df["Main_muscle"].isin(top_muscles)],
```


```

    x="Main_muscle",
    y=rating_col,
)
plt.xticks(rotation=45, ha="right")
plt.title("Distribution de la difficulté par muscle principal (Top 8)")
plt.grid(True, axis="y")
plt.tight_layout()
plt.show()

```

	count	mean
Equipment		
Assisted (machine)	3	4.000000
Assisted (partner)	2	4.000000
Band-assisted	7	3.857143
Suspension	2	3.500000
Self-assisted	6	3.500000
Plyometric	2	3.500000
Self-assisted	5	3.400000
Body Weight	76	3.315789
Weighted	34	3.205882
Barbell	57	3.017544
Assisted	4	3.000000
Assisted Chest Dip	1	3.000000
Smith	1	3.000000
Lever (selectorized) Chest Dip	1	3.000000
Weighted Chest Dip	1	3.000000





1.6.4 Co-occurrences entre catégories (crosstab + heatmaps)

On s'intéresse ensuite aux co-occurrences entre catégories, par exemple les combinaisons Equipment × Main_muscle, pour repérer les couples les plus fréquents.

```
[23]: # Sélection d'un sous-ensemble lisible : top équipements / top muscles
top_equip_for_cooc = df["Equipment"].value_counts().head(8).index
top_muscles_for_cooc = df["Main_muscle"].value_counts().head(8).index

subset = df[
    df["Equipment"].isin(top_equip_for_cooc)
    & df["Main_muscle"].isin(top_muscles_for_cooc)
]

cooc = pd.crosstab(subset["Equipment"], subset["Main_muscle"])

display(cooc)

def plot_crosstab_heatmaps(
    df,
    pairs,
    top_k=12,
    normalize=None,      # None / "row" / "col" (pourcentages)
    annotate=False,      # True pour afficher les valeurs
    log_color=False,     # True pour mieux voir les faibles valeurs
```

```

figsize=(16, 9),
title_fontsize=13,
tick_fontsize=9,
label_rotation_x=30,
label_rotation_y=0,
cbar_shrink=0.85
):
    """Heatmaps propres et lisibles pour analyser les co-occurrences de ↵
    catégories."""
    if not pairs:
        print(" Aucune paire de catégories disponible.")
        return

    n = len(pairs)
    ncols = 2
    nrows = (n + ncols - 1) // ncols
    fig, axes = plt.subplots(nrows=nrows, ncols=ncols, figsize=figsize)
    axes = np.atleast_1d(axes).ravel()

    for i, (a, b) in enumerate(pairs):
        ax = axes[i]

        # Top-k pour réduire la cardinalité (plus lisible)
        a_top = df[a].value_counts().index[:top_k]
        b_top = df[b].value_counts().index[:top_k]
        sub = df[df[a].isin(a_top) & df[b].isin(b_top)]

        ct = pd.crosstab(sub[a], sub[b])

        # Normalisation optionnelle en pourcentages
        if normalize in {"row", "col"}:
            axis = 1 if normalize == "row" else 0
            ct = (
                ct.div(
                    ct.sum(axis=axis).replace(0, np.nan),
                    axis=1-axis
                ) * 100
            ).round(1)

        # Palette & échelle adaptées
        heatmap_kwargs = dict(
            cmap="crest",
            linewidths=0.4,
            linecolor="grey",
            cbar_kws={"shrink": cbar_shrink},
            square=False,
        )

```

```

if log_color and normalize is None:
    # Log uniquement pour les comptes bruts (pas en %)
    vmin = max(ct.replace(0, np.nan).min().min(), 1e-6)
    vmax = ct.max().max()
    heatmap_kwargs["norm"] = LogNorm(vmin=vmin, vmax=vmax)

# Annotations optionnelles
if annotate:
    sns.heatmap(
        ct,
        ax=ax,
        **heatmap_kwargs,
        annot=True,
        fmt=".1f" if normalize else "g",
        annot_kws={"fontsize": max(tick_fontsize - 1, 7)},
    )
else:
    sns.heatmap(ct, ax=ax, **heatmap_kwargs)

ax.set_title(
    f"Co-occurrences {a} × {b} (top {top_k})",
    fontsize=title_fontsize,
    pad=8,
)
ax.set_xlabel(b, fontsize=10)
ax.set_ylabel(a, fontsize=10)

# Ticks propres
ax.tick_params(axis="x", labelsize=tick_fontsize,
↪rotation=label_rotation_x)
ax.tick_params(axis="y", labelsize=tick_fontsize,
↪rotation=label_rotation_y)
ax.grid(False)

# Masquer axes vides si nombre impair
for j in range(i + 1, nrows * ncols):
    fig.delaxes(axes[j])

plt.tight_layout()
plt.show()

# =====
# Sélection des paires & appel (version Gym Exercises Dataset)
# =====
pairs = []
if {"Equipment", "Main_muscle"}.issubset(df.columns):

```

```

    pairs.append(("Equipment", "Main_muscle"))
if {"Equipment", "Utility"}.issubset(df.columns):
    pairs.append(("Equipment", "Utility"))
if {"Main_muscle", "Utility"}.issubset(df.columns):
    pairs.append(("Main_muscle", "Utility"))
if {"Main_muscle", "Force"}.issubset(df.columns):
    pairs.append(("Main_muscle", "Force"))
if {"Main_muscle", "Mechanics"}.issubset(df.columns):
    pairs.append(("Main_muscle", "Mechanics"))

# Paramètres recommandés pour notre dataset :
# - normalize="row" pour lire des ratios par catégorie de ligne
# - annotate=False pour éviter la surcharge visuelle
# - log_color=False car on travaille en %
plot_crosstab_heatmaps(
    df,
    pairs=pairs,
    top_k=10,
    normalize="row",      # None = comptes bruts ; "row"/"col" = pourcentages
    annotate=False,
    log_color=False,
    figsize=(16, 10),
    title_fontsize=14,
    tick_fontsize=10,
    label_rotation_x=40,
    label_rotation_y=0,
    cbar_shrink=0.8,
)

```

Main_muscle	Back	Calves	Chest	Forearm	Hips	Shoulder	Thighs	
↳ Upper Arms								
Equipment								
Barbell	5	3	5	3	14	5	15	↳
↳ 7								
Body Weight	10	4	8	0	26	4	14	↳
↳ 7								
Cable	21	4	12	4	18	16	9	↳
↳ 15								
Dumbbell	7	4	7	5	8	15	8	↳
↳ 8								
Lever (plate loaded)	16	9	7	3	14	7	12	↳
↳ 5								
Lever (selectorized)	11	8	13	6	14	6	12	↳
↳ 7								
Sled	1	12	1	0	9	1	6	↳
↳ 1								

Weighted



2

4

1


2

0

16

0

5



1.6.5 Comptage empilé (stacked) : Type au sein du top Equipment

Pour finir, on observe la répartition des types d'exercices (Utility : Basic or Auxiliary / Auxiliary, etc.) au sein des équipements les plus représentés.

```
[24]: # On retient les équipements les plus fréquents
top Equip_for_stack = df["Equipment"].value_counts().head(6).index
stack_subset = df[df["Equipment"].isin(top Equip_for_stack)].copy()

crosstab_utility = pd.crosstab(stack_subset["Equipment"],
    ↪stack_subset["Utility"])
display(crosstab_utility)

# Normalisation en pourcentage pour lecture plus intuitive
crosstab_utility_pct = crosstab_utility.div(crosstab_utility.sum(axis=1),
    ↪axis=0) * 100

plt.figure(figsize=(9, 5))

bottom = np.zeros(len(crosstab_utility_pct))
x = np.arange(len(crosstab_utility_pct.index))
```

```

for utility in crosstab_utility_pct.columns:
    values = crosstab_utility_pct[utility].values
    plt.bar(
        x,
        values,
        bottom=bottom,
        label=utility,
    )
    bottom += values

plt.xticks(x, crosstab_utility_pct.index, rotation=45, ha="right")
plt.ylabel("Proportion (%)")
plt.title("Répartition des types d'exercices (Utility) au sein du Top Equipments")
plt.legend(title="Utility", bbox_to_anchor=(1.05, 1), loc="upper left")
plt.tight_layout()
plt.show()

```

Utility	Auxiliary	Basic	Basic or Auxiliary
Equipment			
Barbell	20	19	18
Body Weight	22	17	37
Cable	45	17	39
Dumbbell	32	9	21
Lever (plate loaded)	19	38	19
Lever (selectorized)	32	29	19

