

eda_health_fitness_dataset_v1.0

November 18, 2025

1 EDA – FitLife Health & Fitness Tracking Dataset

Ce notebook explore le dataset **FitLife Health & Fitness Tracking** dans le cadre du projet TrAIn.me.

L'objectif est de vérifier la qualité des données (structure, typage, complétude) avant toute modélisation prédictive.

1.1 Objectif

Vérifier que le fichier `health_fitness_dataset.csv` est correctement chargé et obtenir une vue d'ensemble :

- dimensions du jeu de données (nombre de lignes et de colonnes) ;
- typage des variables (numériques, catégorielles) ;
- première inspection des valeurs manquantes et des doublons ;
- cohérence générale du corpus avant analyse statistique détaillée.

1.2 Interprétation attendue

À partir de cette première inspection, il s'agira de commenter :

- la taille globale du dataset (nombre de lignes / colonnes) ;
- la nature des variables (mélange de mesures numériques, indicateurs de santé et catégories) ;
- la présence éventuelle de valeurs manquantes et leur concentration sur certaines colonnes ;
- l'existence (ou non) de doublons dans les données brutes ;
- la cohérence générale des premières lignes (valeurs réalistes, formats attendus).

Cette interprétation sert de point de départ pour juger de la qualité du corpus et décider des premières actions de nettoyage à mener dans les sections suivantes.

1.3 Configuration notebook

1.3.1 Importation des librairies essentielles

```
[4]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import kagglehub
```

```

from pathlib import Path
import sys

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
root = Path.cwd() # ex : .../train.me/src/notebooks/eda/health_fitness_dataset
themes_root = None

for p in [root, *root.parents]:
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence : il doit exister un dossier 'themes/' quelque
↳part au-dessus."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print(" Ajouté au PYTHONPATH :", themes_root)
print(" Contenu de", themes_root, ":", [x.name for x in themes_root.iterdir()])

from themes.theme_train_me import set_trainme_theme

```

Ajouté au PYTHONPATH :

c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks

Contenu de c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks :

['eda', 'model_training', 'preprocessing', 'themes', '__init__.py']

c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\conda\Lib\site-packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update jupyter and ipywidgets. See https://ipywidgets.readthedocs.io/en/stable/user_install.html

from .autonotebook import tqdm as notebook_tqdm

Configuration d'affichage et thème TrAIIn.me

```

[5]: # Options d'affichage pour les tableaux
pd.set_option("display.max_columns", None)
pd.set_option("display.width", 120)

# =====
# Thème TrAIIn.me (Seaborn/Matplotlib)
# =====

```

```
USE_DARK_THEME = True # bascule possible vers un thème clair si besoin

palette_trainme = set_trainme_theme(
    context="talk",
    font_scale=1.05,
    use_dark=USE_DARK_THEME
)

palette_trainme
```

[5]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']

1.4 Chargement et inspection initiale

Chargement du dataset `health_fitness_dataset.csv`

```
[6]: # Téléchargement du dataset depuis Kaggle
dataset_path = kagglehub.dataset_download("jijagallery/
↳fitlife-health-and-fitness-tracking-dataset")

# Recherche du fichier CSV dans le dossier téléchargé
csv_files = [f for f in os.listdir(dataset_path) if f.endswith(".csv")]
print("Fichiers trouvés :", csv_files)

# Construction du chemin complet vers le CSV
file_path = os.path.join(dataset_path, csv_files[0])

# Lecture du fichier CSV
df = pd.read_csv(file_path)

# Informations de confirmation
print("Dataset chargé avec succès !")
print(f"Dimensions : {df.shape[0]} lignes et {df.shape[1]} colonnes\n")
```

Downloading from
https://www.kaggle.com/api/v1/datasets/download/jijagallery/fitlife-health-and-fitness-tracking-dataset?dataset_version_number=1...

100%| | 15.4M/15.4M [00:03<00:00, 5.10MB/s]

Extracting files...

Fichiers trouvés : ['health_fitness_dataset.csv']
 Dataset chargé avec succès !
 Dimensions : 687701 lignes et 22 colonnes

Aperçu des premières lignes

```
[7]: df.head(10)
```

```
[7]:   participant_id      date  age gender  height_cm  weight_kg  activity_type
duration_minutes intensity \
0              1  2024-01-01   56     F    165.3    53.7      Dancing
41           Low
1              1  2024-01-04   56     F    165.3    53.9      Swimming
28           Low
2              1  2024-01-05   56     F    165.3    54.2      Swimming
21      Medium
3              1  2024-01-07   56     F    165.3    54.4  Weight Training
99      Medium
4              1  2024-01-09   56     F    165.3    54.7      Swimming
100     Medium
5              1  2024-01-10   56     F    165.3    54.9      HIIT
31      Medium
6              1  2024-01-11   56     F    165.3    55.2  Weight Training
97           High
7              1  2024-01-12   56     F    165.3    55.5      HIIT
70           Low
8              1  2024-01-17   56     F    165.3    55.7      HIIT
89      Medium
9              1  2024-01-18   56     F    165.3    56.0  Weight Training
115     Medium
```

```
   calories_burned  avg_heart_rate  hours_sleep  stress_level  daily_steps
hydration_level  bmi  resting_heart_rate \
0              3.3          103          6.6          3          7128
1.5  19.6          69.5
1              2.9          102          8.1          7          7925
1.8  19.6          69.5
2              2.6          126          6.2          7          7557
2.7  19.6          69.5
3              10.7          141          7.2          8          11120
2.6  19.6          69.5
4              12.7          112          7.1          1          5406
1.5  19.6          69.5
5              6.8          121          7.5          10         10202
2.2  19.6          69.5
6              12.4          145          6.6          8          5912
2.8  19.6          69.5
7              12.9          99          6.1          7          9477
1.6  19.6          69.5
8              19.7          112          7.2          7          9710
3.3  19.6          69.5
9              12.8          117          5.6          3          7830
2.0  19.6          69.5
```

	blood_pressure_systolic	blood_pressure_diastolic	health_condition
0	110.7	72.9	NaN
Never	0.04		
1	110.7	72.9	NaN
Never	0.07		
2	110.7	72.9	NaN
Never	0.09		
3	110.7	72.9	NaN
Never	0.21		
4	110.7	72.9	NaN
Never	0.33		
5	110.7	72.9	NaN
Never	0.37		
6	110.7	72.9	NaN
Never	0.51		
7	110.7	72.9	NaN
Never	0.58		
8	110.7	72.9	NaN
Never	0.68		
9	110.7	72.9	NaN
Never	0.82		

Informations sur le typage, les valeurs manquantes et les doublons

```
[8]: # Typage et complétude globale
df_info = df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 687701 entries, 0 to 687700
Data columns (total 22 columns):
#   Column                Non-Null Count  Dtype
---  -
0   participant_id         687701 non-null  int64
1   date                   687701 non-null  object
2   age                    687701 non-null  int64
3   gender                  687701 non-null  object
4   height_cm              687701 non-null  float64
5   weight_kg              687701 non-null  float64
6   activity_type          687701 non-null  object
7   duration_minutes       687701 non-null  int64
8   intensity              687701 non-null  object
9   calories_burned        687701 non-null  float64
10  avg_heart_rate         687701 non-null  int64
11  hours_sleep            687701 non-null  float64
12  stress_level           687701 non-null  int64
13  daily_steps            687701 non-null  int64
```

```

14 hydration_level      687701 non-null float64
15 bmi                  687701 non-null float64
16 resting_heart_rate   687701 non-null float64
17 blood_pressure_systolic 687701 non-null float64
18 blood_pressure_diastolic 687701 non-null float64
19 health_condition     197426 non-null object
20 smoking_status       687701 non-null object
21 fitness_level        687701 non-null float64
dtypes: float64(10), int64(6), object(6)
memory usage: 115.4+ MB

```

1.4.1 Statistiques descriptives des variables numériques

```
[9]: display(df.describe().T)
```

	count	mean	std	min	25%	75%	max
participant_id	687701.0	1499.781828	865.997215	1.00	749.00	2249.00	3000.00
age	687701.0	41.658602	13.581770	18.00	30.00	53.00	64.00
height_cm	687701.0	168.587699	9.140811	145.00	161.70	175.30	198.50
weight_kg	687701.0	94.921981	22.461801	45.30	78.20	110.50	188.40
duration_minutes	687701.0	70.011671	29.147251	20.00	45.00	95.00	120.00
calories_burned	687701.0	15.381302	9.985552	0.80	7.80	20.70	92.00
avg_heart_rate	687701.0	131.454165	17.814744	82.00	118.00	144.00	206.00
hours_sleep	687701.0	7.048799	0.972068	4.00	6.40	7.70	10.00
stress_level	687701.0	5.252389	2.770029	1.00	3.00	8.00	10.00
daily_steps	687701.0	8628.370918	2054.756608	-419.00	7203.00	10027.00	17241.00
hydration_level	687701.0	2.499427	0.579050	1.50	2.00	3.00	3.50
bmi	687701.0	22.733134	3.568383	14.20	20.10	25.10	38.80
resting_heart_rate	687701.0	70.010547	5.074563	51.10	66.50	73.50	87.10
blood_pressure_systolic	687701.0	120.001260	10.008917	78.00	113.10	127.00	152.70
blood_pressure_diastolic	687701.0	80.188079	8.239418	53.70	74.60	85.70	112.10

fitness_level	687701.0	9.524900	5.502485	0.02	4.77	□
↪ 9.51	14.23	21.93				

1.4.2 Analyse des valeurs manquantes et doublons

```
[10]: # Comptage des valeurs manquantes par colonne
missing_counts = df.isna().sum().sort_values(ascending=False)

print("\n Valeurs manquantes par colonne (top 20) :")
display(missing_counts.head(20))

# Comptage des doublons ligne à ligne
n_duplicates = df.duplicated().sum()
print(f"\n Nombre de doublons (lignes strictement identiques) : □
↪ {n_duplicates}")
```

Valeurs manquantes par colonne (top 20) :

health_condition	490275
participant_id	0
date	0
smoking_status	0
blood_pressure_diastolic	0
blood_pressure_systolic	0
resting_heart_rate	0
bmi	0
hydration_level	0
daily_steps	0
stress_level	0
hours_sleep	0
avg_heart_rate	0
calories_burned	0
intensity	0
duration_minutes	0
activity_type	0
weight_kg	0
height_cm	0
gender	0
dtype: int64	

Nombre de doublons (lignes strictement identiques) : 0

1.4.3 Liste complète des colonnes disponibles

```
[11]: print("\n--- Liste des colonnes du dataset ---")  
      print(df.columns.tolist())
```

```
--- Liste des colonnes du dataset ---  
['participant_id', 'date', 'age', 'gender', 'height_cm', 'weight_kg',  
'activity_type', 'duration_minutes', 'intensity', 'calories_burned',  
'avg_heart_rate', 'hours_sleep', 'stress_level', 'daily_steps',  
'hydration_level', 'bmi', 'resting_heart_rate', 'blood_pressure_systolic',  
'blood_pressure_diastolic', 'health_condition', 'smoking_status',  
'fitness_level']
```