

eda_programm_summury_v1.0

December 12, 2025

1 EDA - programm_summury.csv

1.0.1 Chargement et inspection initiale

Objectif Charger les fichiers du dataset **600K+ Fitness Exercise & Workout Program Dataset** et obtenir une première vue d'ensemble :

- dimensions de chaque fichier (lignes / colonnes) ;
- aperçu des premières lignes (cohérence des champs) ;
- typage des variables et complétude (valeurs manquantes) ;
- présence éventuelle de doublons ;
- liste complète des colonnes disponibles.

Cette étape valide que le corpus est exploitable avant nettoyage et préparation NLP pour le projet **TrAIIn.me**.

Interprétation attendue À l'issue de cette première inspection, on commentera :

- la taille du dataset (volume “exercice” vs volume “programmes”) ;
- la nature des variables : textes (title/description), catégories (level/goal/equipment), structure (week/day), paramètres d'entraînement (sets/ reps/intensity), métadonnées (times-tamps) ;
- la présence de valeurs manquantes et leur ordre de grandeur ;
- l'existence (ou non) de doublons stricts ;
- la cohérence générale des premières lignes (valeurs lisibles, structure logique, champs textuels non vides).

Ce diagnostic sert de référence avant les étapes de nettoyage, normalisation et structuration pour le Deep Learning / NLP.

1.0.2 Importation des librairies essentielles

```
[1]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import LogNorm
import textwrap
from matplotlib.ticker import PercentFormatter
import seaborn as sns
```

```

import kagglehub
import prince

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
from pathlib import Path
import sys

root = Path.cwd()          # ex: .../DuckDB/eda/life_style_data
themes_root = None

for p in [root, *root.parents]:  # remonte: life_style_data -> eda -> DuckDB
    ↳-> ...
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence (il doit exister un dossier 'themes/' quelque
        ↳part au-dessus)."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print("Ajouté au PYTHONPATH :", themes_root)
print("Contenu de", themes_root, ":", [x.name for x in (themes_root).iterdir()])

# Thème personnalisé du projet (uniquement pour les notebooks)
from themes.theme_train_me import set_trainme_theme

```

```

c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\conda\Lib\site-
packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
    from .autonotebook import tqdm as notebook_tqdm

```

```

Ajouté au PYTHONPATH :
c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks
Contenu de c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks :
['dataset_fusion', 'eda', 'model_training', 'preprocessing', 'themes',
'__init__.py', '__pycache__']

```

1.0.3 Configuration d’affichage pour plus de lisibilité

```
[2]: pd.set_option('display.max_columns', None)
pd.set_option('display.width', 120)
```

1.0.4 Thème “TrAIn.me”

Il applique un fond dark propre, une grille discrète, des ticks lisibles, et une palette bleus/cians cohérente.

```
[3]: # =====
# Thème TrAIn.me (Seaborn/Matplotlib)
# =====
# Booléen de contrôle : True = thème TrAIn.me (dark), False = style clair
# ↪ "ticks"
USE_DARK_THEME = True # modifie ici selon le contexte

# Activer le thème au début du notebook :
palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
# ↪ use_dark=True)
palette_trainme
```

```
[3]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']
```

1.0.5 Chargement du dataset

```
[6]: # Téléchargement du dataset depuis Kaggle
# Identifiant Kaggle attendu : "adnanelouardi/
# ↪ 600k-fitness-exercise-and-workout-program-dataset"
dataset_path = kagglehub.dataset_download("adnanelouardi/
# ↪ 600k-fitness-exercise-and-workout-program-dataset")
print("Dataset téléchargé dans :", dataset_path)

# Recherche des CSV disponibles
csv_files = sorted([f for f in os.listdir(dataset_path) if f.endswith(".csv")])
print("Fichiers CSV trouvés :", csv_files)

# On cible explicitement les deux fichiers décrits dans la page Kaggle
path_programs = os.path.join(dataset_path, "program_summary.csv")

# Chargement
df = pd.read_csv(path_programs)

print("Chargement terminé.")
print(f"program_summary.csv : {df.shape[0]:,} lignes | {df.shape[1]:,}
# ↪ colonnes")
```

Dataset téléchargé dans :
C:\Users\fback\.cache\kagglehub\datasets\adnanelouardi\600k-fitness-exercise-and-workout-program-dataset\versions\1
Fichiers CSV trouvés : ['program_summary.csv',
'programs_detailed_boostcamp_kaggle.csv']
Chargement terminé.
program_summary.csv : 2,598 lignes | 10 colonnes

1.0.6 Aperçu général des premières lignes

[7]: `display(df.head())`

	description \	title		
0	(MASS MONSTER) High Intensity 4 Day Upper Lowe... Build tones of muscular with this high intensi...			
1	(NOT MY PROGRAM)SHJ Jotaro			
2	1 PowerLift Per Day Powerbuilding 5 Day Bro Split Based off of Andy Baker's KCS (Kingwood Streng...			
3	10 Week Mass Building Program This workout is designed to increase your musc...			
4	10 week deadlift focus			
	Increase deadlift			
	goal equipment \	level		
0	['Intermediate'] ['Muscle & Sculpting', 'Bodyweight Fitness'] Full Gym			
1	['Advanced', 'Intermediate'] ['Bodybuilding'] Full Gym			
2	['Beginner', 'Novice', 'Intermediate'] ['Athletics', 'Powerlifting', 'Powerbuilding'] Full Gym			
3	['Intermediate', 'Advanced'] ['Powerbuilding'] Garage Gym			
4	['Intermediate', 'Advanced'] ['Powerbuilding', 'Powerlifting', 'Bodybuildin...'] Full Gym			
	program_length	time_per_workout	total_exercises	created
	last_edit			
0	12.0	90.0	384	2024-01-20 10:23:00
	2025-06-29 12:39:00			
1	8.0	60.0	224	2024-07-08 02:28:00
	2025-06-18 09:15:00			
2	6.0	90.0	237	2025-04-23 09:21:00
	2025-06-18 11:55:00			

```

3          10.0          70.0          280  2024-09-07 03:44:00
↳2025-06-18 08:01:00
4          10.0          80.0          356  2024-12-23 03:13:00
↳2025-06-18 12:19:00

```

1.0.7 Informations générales sur le typage et la complétude

```
[8]: df_info = df.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2598 entries, 0 to 2597
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   title                 2598 non-null  object
1   description           2594 non-null  object
2   level                 2598 non-null  object
3   goal                 2598 non-null  object
4   equipment             2597 non-null  object
5   program_length        2597 non-null  float64
6   time_per_workout      2598 non-null  float64
7   total_exercises       2598 non-null  int64
8   created               2597 non-null  object
9   last_edit             2596 non-null  object
dtypes: float64(2), int64(1), object(7)
memory usage: 203.1+ KB

```

1.0.8 Statistiques descriptives des variables numériques

```
[9]: display(df.describe().T)
```

```

count      mean      std   min    25%    50%    75%
↳max
program_length  2597.0   8.812476   4.185403   1.0    5.0    8.0   12.00
↳18.0
time_per_workout  2598.0  69.035412  24.394798  10.0   60.0   60.0   90.00
↳180.0
total_exercises  2598.0  232.884142  208.123873   1.0  108.0  192.5  307.75
↳5040.0

```

1.0.9 Analyse des valeurs manquantes et doublons

```

[10]: missing_values = df.isnull().sum().sort_values(ascending=False)
duplicates = df.duplicated().sum()

print("\n--- Valeurs manquantes par colonne (top 10) ---")
display(missing_values.head(10))

```

```
print(f"\nNombre total de doublons détectés : {duplicates}")
```

--- Valeurs manquantes par colonne (top 10) ---

```
description      4
last_edit        2
equipment        1
program_length   1
created          1
title            0
level            0
goal             0
time_per_workout 0
total_exercises  0
dtype: int64
```

Nombre total de doublons détectés : 0

1.0.10 Liste complète des colonnes disponibles

```
[11]: print("\n--- Liste des colonnes du dataset ---")
      print(df.columns.tolist())
```

--- Liste des colonnes du dataset ---

```
['title', 'description', 'level', 'goal', 'equipment', 'program_length',
'time_per_workout', 'total_exercises', 'created', 'last_edit']
```