

eda_programm_summury_v1.3

December 12, 2025

1 EDA - programm_summury.csv

1.1 Chargement et inspection initiale

Objectif Charger les fichiers du dataset **600K+ Fitness Exercise & Workout Program Dataset** et obtenir une première vue d'ensemble :

- dimensions de chaque fichier (lignes / colonnes) ;
- aperçu des premières lignes (cohérence des champs) ;
- typage des variables et complétude (valeurs manquantes) ;
- présence éventuelle de doublons ;
- liste complète des colonnes disponibles.

Cette étape valide que le corpus est exploitable avant nettoyage et préparation NLP pour le projet **TrAIn.me**.

Interprétation attendue À l'issue de cette première inspection, on commentera :

- la taille du dataset (volume “exercice” vs volume “programmes”) ;
- la nature des variables : textes (title/description), catégories (level/goal/equipment), structure (week/day), paramètres d'entraînement (sets/ reps/intensity), métadonnées (times-tamps) ;
- la présence de valeurs manquantes et leur ordre de grandeur ;
- l'existence (ou non) de doublons stricts ;
- la cohérence générale des premières lignes (valeurs lisibles, structure logique, champs textuels non vides).

Ce diagnostic sert de référence avant les étapes de nettoyage, normalisation et structuration pour le Deep Learning / NLP.

1.1.1 Importation des librairies essentielles

```
[1]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.colors import LogNorm
import textwrap
from matplotlib.ticker import PercentFormatter
import seaborn as sns
```

```

import kagglehub
import prince

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
from pathlib import Path
import sys

root = Path.cwd()          # ex: .../DuckDB/eda/life_style_data
themes_root = None

for p in [root, *root.parents]:  # remonte: life_style_data -> eda -> DuckDB
    ↳-> ...
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence (il doit exister un dossier 'themes/' quelque
        ↳part au-dessus)."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print("Ajouté au PYTHONPATH :", themes_root)
print("Contenu de", themes_root, ":", [x.name for x in (themes_root).iterdir()])

# Thème personnalisé du projet (uniquement pour les notebooks)
from themes.theme_train_me import set_trainme_theme

```

```

c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\conda\Lib\site-
packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
    from .autonotebook import tqdm as notebook_tqdm

```

```

Ajouté au PYTHONPATH :
c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks
Contenu de c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks :
['dataset_fusion', 'eda', 'model_training', 'preprocessing', 'themes',
'__init__.py', '__pycache__']

```

1.1.2 Configuration d’affichage pour plus de lisibilité

```
[2]: pd.set_option('display.max_columns', None)
pd.set_option('display.width', 120)
```

1.1.3 Thème “TrAIn.me”

Il applique un fond dark propre, une grille discrète, des ticks lisibles, et une palette bleus/cians cohérente.

```
[3]: # =====
# Thème TrAIn.me (Seaborn/Matplotlib)
# =====
# Booléen de contrôle : True = thème TrAIn.me (dark), False = style clair
# ↪ "ticks"
USE_DARK_THEME = True # modifie ici selon le contexte

# Activer le thème au début du notebook :
palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
# ↪ use_dark=True)
palette_trainme
```

```
[3]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']
```

1.1.4 Chargement du dataset

```
[6]: # Téléchargement du dataset depuis Kaggle
# Identifiant Kaggle attendu : "adnanelouardi/
# ↪ 600k-fitness-exercise-and-workout-program-dataset"
dataset_path = kagglehub.dataset_download("adnanelouardi/
# ↪ 600k-fitness-exercise-and-workout-program-dataset")
print("Dataset téléchargé dans :", dataset_path)

# Recherche des CSV disponibles
csv_files = sorted([f for f in os.listdir(dataset_path) if f.endswith(".csv")])
print("Fichiers CSV trouvés :", csv_files)

# On cible explicitement les deux fichiers décrits dans la page Kaggle
path_programs = os.path.join(dataset_path, "program_summary.csv")

# Chargement
df = pd.read_csv(path_programs)

print("Chargement terminé.")
print(f"program_summary.csv : {df.shape[0]:,} lignes | {df.shape[1]:,}
# ↪ colonnes")
```

Dataset téléchargé dans :
C:\Users\fback\.cache\kagglehub\datasets\adnanelouardi\600k-fitness-exercise-and-workout-program-dataset\versions\1
Fichiers CSV trouvés : ['program_summary.csv',
'programs_detailed_boostcamp_kaggle.csv']
Chargement terminé.
program_summary.csv : 2,598 lignes | 10 colonnes

1.1.5 Aperçu général des premières lignes

```
[7]: display(df.head())
```

		title	
	description \		
0	(MASS MONSTER) High Intensity 4 Day Upper Lowe...	Build tones of muscular with	
	this high intensi...		
1	(NOT MY PROGRAM)SHJ Jotaro		
	Build strength and size		
2	1 PowerLift Per Day Powerbuilding 5 Day Bro Split Based off of Andy Baker's		
	KCS (Kingwood Streng...		
3	10 Week Mass Building Program This workout is designed		
	to increase your musc...		
4	10 week deadlift focus		
	Increase deadlift		
	goal	equipment \	level
0	['Intermediate']	['Muscle & Sculpting',	
	'Bodyweight Fitness']	Full Gym	
1	['Advanced', 'Intermediate']		
	['Bodybuilding']	Full Gym	
2	['Beginner', 'Novice', 'Intermediate']	['Athletics', 'Powerlifting',	
	'Powerbuilding']	Full Gym	
3	['Intermediate', 'Advanced']		
	['Powerbuilding']	Garage Gym	
4	['Intermediate', 'Advanced']	['Powerbuilding', 'Powerlifting',	
	'Bodybuildin...	Full Gym	
	program_length	time_per_workout	total_exercises
	last_edit		created
0	12.0	90.0	384
	2025-06-29 12:39:00		2024-01-20 10:23:00
1	8.0	60.0	224
	2025-06-18 09:15:00		2024-07-08 02:28:00
2	6.0	90.0	237
	2025-06-18 11:55:00		2025-04-23 09:21:00

```

3          10.0          70.0          280  2024-09-07 03:44:00
↳2025-06-18 08:01:00
4          10.0          80.0          356  2024-12-23 03:13:00
↳2025-06-18 12:19:00

```

1.1.6 Informations générales sur le typage et la complétude

```
[8]: df_info = df.info()
```

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2598 entries, 0 to 2597
Data columns (total 10 columns):
#   Column                Non-Null Count  Dtype
---  -
0   title                 2598 non-null   object
1   description            2594 non-null   object
2   level                 2598 non-null   object
3   goal                  2598 non-null   object
4   equipment             2597 non-null   object
5   program_length        2597 non-null   float64
6   time_per_workout      2598 non-null   float64
7   total_exercises       2598 non-null   int64
8   created               2597 non-null   object
9   last_edit             2596 non-null   object
dtypes: float64(2), int64(1), object(7)
memory usage: 203.1+ KB

```

1.1.7 Statistiques descriptives des variables numériques

```
[9]: display(df.describe().T)
```

```

count      mean      std   min   25%   50%   75%
↳max
program_length  2597.0   8.812476   4.185403   1.0    5.0    8.0   12.00
↳18.0
time_per_workout  2598.0  69.035412  24.394798  10.0   60.0   60.0   90.00
↳180.0
total_exercises  2598.0  232.884142  208.123873   1.0  108.0  192.5  307.75
↳5040.0

```

1.1.8 Analyse des valeurs manquantes et doublons

```

[10]: missing_values = df.isnull().sum().sort_values(ascending=False)
duplicates = df.duplicated().sum()

print("\n--- Valeurs manquantes par colonne (top 10) ---")
display(missing_values.head(10))

```

```
print(f"\nNombre total de doublons détectés : {duplicates}")
```

--- Valeurs manquantes par colonne (top 10) ---

```
description      4
last_edit        2
equipment         1
program_length   1
created          1
title            0
level            0
goal             0
time_per_workout 0
total_exercises  0
dtype: int64
```

Nombre total de doublons détectés : 0

1.1.9 Liste complète des colonnes disponibles

```
[11]: print("\n--- Liste des colonnes du dataset ---")
      print(df.columns.tolist())
```

--- Liste des colonnes du dataset ---

```
['title', 'description', 'level', 'goal', 'equipment', 'program_length',
'time_per_workout', 'total_exercises', 'created', 'last_edit']
```

1.2 Statistiques descriptives et distribution des variables

Objectif Obtenir une vue d’ensemble chiffrée des variables numériques du dataset **program_summary.csv** :

- résumer la distribution des variables disponibles (durée du programme, durée par séance, volume total d’exercices) ;
- repérer les ordres de grandeur, la dispersion et les éventuelles valeurs extrêmes ;
- préparer l’identification d’outliers et la sélection de variables pertinentes pour la suite de l’analyse.

Interprétation attendue À l’issue de cette section, l’interprétation devra mettre en évidence :

- les valeurs centrales des variables clés (durée typique des programmes, temps moyen par séance, volume global d’exercices) ;
- la dispersion (écarts-types, min/max, quartiles) afin d’identifier des programmes “courts” vs “longs”, et des programmes “légers” vs “très volumineux” ;
- la présence éventuelle de valeurs extrêmes ou atypiques (ex. volume d’exercices très élevé) pouvant nécessiter un traitement spécifique ;

- les premières tendances structurantes utiles pour le projet **TrAIn.me** (plages réalistes à cibler lors de la génération de programmes).

1.2.1 Activation du thème TrAIn.me

```
[12]: if USE_DARK_THEME:
    palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
    ↪use_dark=True)
else:
    sns.set_style("ticks")           # style clair sobre, axes renforcés
    sns.set_context("talk", font_scale=1.05)
    palette_trainme = sns.color_palette("deep") # palette par défaut sobre
    print("Style activé : 'ticks' → sobre, axes renforcés (présentation pro)")

# Exemple de vérification :
print("Palette active :", palette_trainme.as_hex() if hasattr(palette_trainme,
    ↪"as_hex") else palette_trainme)
```

Palette active : ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']

1.3 Statistiques descriptives globales

```
[13]: # --- Colonnes numériques disponibles ---
num_cols = df.select_dtypes(include="number").columns.tolist()
print(f"Variables numériques détectées ({len(num_cols)}) : {num_cols}")

# Statistiques descriptives de base
if num_cols:
    stats_num = df[num_cols].describe().T
    display(stats_num)
else:
    print("Aucune variable numérique détectée.")

# Quelques repères métier (si les colonnes existent)
if "program_length" in df.columns:
    print(f"\nDurée moyenne du programme (semaines) : {df['program_length'].
    ↪mean():.2f}")

if "time_per_workout" in df.columns:
    print(f"Temps moyen par séance (minutes) : {df['time_per_workout'].mean():.
    ↪2f}")

if "total_exercises" in df.columns:
    print(f"Nombre total moyen d'exercices par programme :
    ↪{df['total_exercises'].mean():.2f}")
```

Variables numériques détectées (3) : ['program_length', 'time_per_workout',

	count	mean	std	min	25%	50%	75%	
↪max								
program_length	2597.0	8.812476	4.185403	1.0	5.0	8.0	12.00	↪
↪18.0								
time_per_workout	2598.0	69.035412	24.394798	10.0	60.0	60.0	90.00	↪
↪180.0								
total_exercises	2598.0	232.884142	208.123873	1.0	108.0	192.5	307.75	↪
↪5040.0								

Durée moyenne du programme (semaines) : 8.81

Temps moyen par séance (minutes) : 69.04

Nombre total moyen d'exercices par programme : 232.88

1.3.1 Distribution des variables clés

```
[16]: # Variables numériques pertinentes (ici : toutes sont métier)
num_vars = list(num_cols)
print(f"Variables numériques représentées : {num_vars}")


n = len(num_vars)
if n == 0:
    print("Aucune variable numérique pertinente à visualiser.")
else:
    n_cols = 3
    n_rows = int(np.ceil(n / n_cols))

    plt.figure(figsize=(5 * n_cols, 4 * n_rows))

    for i, col in enumerate(num_vars, 1):
        plt.subplot(n_rows, n_cols, i)
        sns.histplot(df[col].dropna(), bins=20, kde=True)
        plt.title(col)
        plt.grid(True, axis="y")

    plt.tight_layout()
    plt.show()
```

Variables numériques représentées : ['program_length', 'time_per_workout', 'total_exercises']




1.3.2 Boxplots pour repérer les outliers

```
[17]: if num_vars:
    plt.figure(figsize=(5 * len(num_vars), 4))

    for i, col in enumerate(num_vars, 1):
        plt.subplot(1, len(num_vars), i)
        sns.boxplot(x=df[col])
        plt.title(col)
        plt.grid(True, axis="x")

    plt.tight_layout()
    plt.show()
else:
    print("Aucun boxplot pertinent à afficher (pas de variable numérique_
    ↪métier).")
```



1.3.3 Statistiques descriptives enrichies

```
[18]: if num_cols:
    desc = df[num_cols].describe().T
    desc["missing_%"] = df[num_cols].isna().mean() * 100
    desc["zeros_%"] = (df[num_cols] == 0).mean() * 100
    desc["skew"] = df[num_cols].skew(numeric_only=True)
    desc["kurt"] = df[num_cols].kurt(numeric_only=True)
```

```

display(desc.sort_values("std", ascending=False))
else:
    print("Aucune variable numérique disponible pour des statistiques enrichies.
↵")

```

	count	mean	std	min	25%	50%	75%	
↵max missing_%	zeros_%	skew \						
total_exercises	2598.0	232.884142	208.123873	1.0	108.0	192.5	307.75	↵
↵5040.0	0.000000	0.0	7.099139					
time_per_workout	2598.0	69.035412	24.394798	10.0	60.0	60.0	90.00	↵
↵180.0	0.000000	0.0	0.727516					
program_length	2597.0	8.812476	4.185403	1.0	5.0	8.0	12.00	↵
↵18.0	0.038491	0.0	0.084756					

	kurt
total_exercises	125.265230
time_per_workout	2.039627
program_length	-0.733091

1.3.4 Détection rapide d'outliers (IQR)

```

[19]: iqr_report = {}

for col in num_cols:
    s = df[col].dropna()
    if s.empty:
        iqr_report[col] = 0
        continue

    Q1 = s.quantile(0.25)
    Q3 = s.quantile(0.75)
    IQR = Q3 - Q1

    outliers = df[(df[col] < Q1 - 1.5 * IQR) | (df[col] > Q3 + 1.5 * IQR)]
    iqr_report[col] = len(outliers)

iqr_df = pd.DataFrame.from_dict(iqr_report, orient="index",
↵columns=["outliers"])
display(iqr_df.sort_values("outliers", ascending=False))


```

	outliers
total_exercises	85
time_per_workout	58
program_length	0

1.3.5 Aperçu corrélations (sous-ensemble lisible)

```
[20]: if len(num_cols) >= 2:
    subset_cols = num_cols # peu de colonnes → heatmap lisible
    corr = df[subset_cols].corr(numeric_only=True)

    plt.figure(figsize=(7, 5))
    sns.heatmap(
        corr,
        annot=True,
        fmt=".2f",
        square=True,
        cbar=True,
        linewidths=0.5,
        annot_kws={"size": 9},
    )
    plt.title("Corrélations (variables numériques)", fontsize=12, pad=10)
    plt.xticks(fontsize=9, rotation=45, ha="right")
    plt.yticks(fontsize=9, rotation=0)
    plt.tight_layout()
    plt.show()
else:
    print("Corrélation non pertinente : une seule variable numérique disponible.
    ↪")
```



1.4 Visualisation univariée

Objectif Compléter les statistiques descriptives par une analyse visuelle des distributions des variables numériques du dataset **program_summary.csv**.

L'objectif est de : - visualiser la forme des distributions (centrage, dispersion, asymétrie) ; - repérer visuellement d'éventuelles valeurs extrêmes (outliers) ; - confirmer les plages réalistes des variables structurantes (durée, temps par séance, volume d'exercices), afin de cadrer les futures étapes de préparation et de génération de programmes pour **TrAIIn.me**.

Interprétation attendue À l'issue de cette section, l'analyse devra : - décrire la distribution des variables numériques (formes dominantes, valeurs typiques) ; - identifier les variables potentiellement asymétriques (ex. "total_exercises" souvent très étalée) ; - signaler les points extrêmes susceptibles de perturber l'entraînement (programmes anormalement longs / volumineux) ; - proposer des pistes de traitement pour la suite (cap, clipping, filtrage, ou pondération) si nécessaire.

1.4.1 Sélection robuste des variables numériques à visualiser

```
[21]: # Colonnes numériques
num_cols = df.select_dtypes(include="number").columns.tolist()

# Filtre de robustesse : au moins 90% de valeurs non-nulles
min_non_null_ratio = 0.90
robust_num_cols = [
    c for c in num_cols
    if df[c].notna().mean() >= min_non_null_ratio
]

# Exclusion éventuelle d'identifiants techniques (si présents dans d'autres
↳ datasets)
excluded = {"id", "program_id", "parent_id"}
robust_num_cols = [c for c in robust_num_cols if c not in excluded]

print(f"Variables numériques détectées : {num_cols}")
print(f"Variables numériques retenues (robustes) : {robust_num_cols}")
```

Variables numériques détectées : ['program_length', 'time_per_workout', 'total_exercises']

Variables numériques retenues (robustes) : ['program_length', 'time_per_workout', 'total_exercises']

1.4.2 Visualisation des distributions univariées (hist + KDE)


```
[22]: import matplotlib.pyplot as plt
import seaborn as sns

if not robust_num_cols:
    print("Aucune variable numérique robuste à visualiser.")
else:
    n = len(robust_num_cols)
    n_cols = 3
    n_rows = int(np.ceil(n / n_cols))

    plt.figure(figsize=(5 * n_cols, 4 * n_rows))

    for i, col in enumerate(robust_num_cols, 1):
        plt.subplot(n_rows, n_cols, i)
        sns.histplot(df[col].dropna(), bins=25, kde=True)
        plt.title(col)
        plt.grid(True, axis="y")

    plt.tight_layout()
    plt.show()
```




1.4.3 Boxplots univariés pour détection visuelle d'outliers

```
[23]: if not robust_num_cols:
    print("Aucun boxplot à afficher.")
else:
    plt.figure(figsize=(5 * len(robust_num_cols), 4))

    for i, col in enumerate(robust_num_cols, 1):
        plt.subplot(1, len(robust_num_cols), i)
        sns.boxplot(x=df[col].dropna())
        plt.title(col)
        plt.grid(True, axis="x")

    plt.tight_layout()
    plt.show()
```



1.5 Visualisation bivariable

Objectif Analyser les relations entre variables **catégorielles** (equipment, level, goal) et **numériques** (program_length, time_per_workout, total_exercises), ainsi que les co-occurrences entre catégories.

Cette étape vise à : - identifier les catégories associées à des programmes plus longs, plus intenses ou plus volumineux ; - comprendre les combinaisons fréquentes (niveau objectifs, équipement objectifs) ; - préparer des règles métier et des contraintes de génération pour TrAIn.me.

Interprétation attendue L'analyse devra mettre en évidence : - les différences de distributions numériques selon l'équipement, le niveau et/ou l'objectif ; - les associations fréquentes entre catégories (ex. certains goals très liés à un niveau ou à un équipement) ; - d'éventuels déséquilibres (catégories très dominantes) pouvant biaiser l'apprentissage ; - des pistes de normalisation (top-N catégories, regroupement, pondération).

1.5.1 Relations catégorielles numérique

```
[24]: # Colonnes attendues côté program_summary
num_cols = [c for c in ["program_length", "time_per_workout",
    ↳"total_exercises"] if c in df.columns]
cat_cols = [c for c in ["equipment", "level", "goal"] if c in df.columns]

print("Numériques :", num_cols)
print("Catégorielles :", cat_cols)

# On limite l'affichage aux catégories les plus fréquentes pour garder des
    ↳graphes lisibles
TOP_N = 10
top_equipment = df["equipment"].value_counts(dropna=False).head(TOP_N).index.
    ↳tolist() if "equipment" in df else []
df_top = df[df["equipment"].isin(top_equipment)].copy() if top_equipment else
    ↳df.copy()

display(df_top[["equipment"] + num_cols].groupby("equipment")[num_cols].
    ↳median().sort_values(num_cols[0], ascending=False) if "equipment" in df_top
    ↳and num_cols else df_top.head())
```

Numériques : ['program_length', 'time_per_workout', 'total_exercises']




Catégorielles : ['equipment', 'level', 'goal']

	program_length	time_per_workout	total_exercises
equipment			
At Home	10.0	50.0	144.0
Full Gym	9.0	70.0	218.5
Dumbbell Only	8.0	50.0	144.0
Garage Gym	8.0	60.0	140.0

1.5.2 Boxplots : numérique par catégorie

```
[25]: if "equipment" in df_top.columns and num_cols:
    for metric in num_cols:
        plt.figure(figsize=(10, 4))
        sns.boxplot(data=df_top, x="equipment", y=metric)
        plt.title(f"{metric} par équipement (Top {TOP_N})")
        plt.xticks(rotation=45, ha="right")
        plt.grid(True, axis="y")
        plt.tight_layout()
```

```
plt.show()
else:
    print("Impossible d'afficher les boxplots : colonnes manquantes ou pas de_
    ↪ variables numériques.")
```



1.5.3 Co-occurrences entre catégories (crosstab + heatmaps)

```
[26]: import ast

def safe_parse_list(x):
    """Convertit "['A','B']" -> ['A','B'] ; sinon renvoie [] si NaN/erreur."""
    if pd.isna(x):
        return []
    if isinstance(x, list):
        return x
    s = str(x).strip()
    try:
        v = ast.literal_eval(s)
        return v if isinstance(v, list) else [v]
    except Exception:
        return [s] if s else []

df_cat = df.copy()

if "level" in df_cat.columns:
    df_cat["level_list"] = df_cat["level"].apply(safe_parse_list)
else:
    df_cat["level_list"] = [[]] * len(df_cat)

if "goal" in df_cat.columns:
    df_cat["goal_list"] = df_cat["goal"].apply(safe_parse_list)
else:
    df_cat["goal_list"] = [[]] * len(df_cat)

# Explode level puis goal
df_expl = df_cat.explode("level_list").explode("goal_list").copy()
df_expl = df_expl.rename(columns={"level_list": "level_item", "goal_list": "goal_item"})

# Filtre top catégories pour lisibilité
TOP_LEVEL = 8
TOP_GOAL = 12

top_levels = df_expl["level_item"].value_counts().head(TOP_LEVEL).index.tolist()
top_goals = df_expl["goal_item"].value_counts().head(TOP_GOAL).index.tolist()

df_heat = df_expl[df_expl["level_item"].isin(top_levels) & df_expl["goal_item"].isin(top_goals)].copy()
```

```
ct = pd.crosstab(df_heat["level_item"], df_heat["goal_item"])
display(ct)
```

goal_item	Athletics	Bodybuilding	Bodyweight	Fitness	Muscle & Sculpting
↪Olympic Weightlifting					
↪Powerbuilding					
↪\					
level_item					
Advanced	186	620		111	322
↪	26	365			
Beginner	210	437		142	286
↪	8	199			
Intermediate	397	1307		218	716
↪	28	760			
Novice	271	862		171	498
↪	14	454			

goal_item	Powerlifting
level_item	
Advanced	205
Beginner	122
Intermediate	383
Novice	248

```
[35]: if not ct.empty:
    ct_norm = ct.div(ct.sum(axis=1), axis=0)

    plt.figure(figsize=(9, 5)) # hauteur augmentée (clé ici)
    ax = sns.heatmap(
        ct_norm,
        annot=True,
        fmt=".2f",
        cmap="viridis",
        linewidths=0.4,
        linecolor="black",
        cbar_kws={"label": "Proportion"},
        annot_kws={
            "size": 8,
            "color": "white",
            "weight": "bold"
        }
    )

    ax.set_aspect("auto") # très important : laisse respirer les lignes


    ax.set_title("Co-occurrences normalisées : level goal", pad=12)
    ax.set_xlabel("goal")
    ax.set_ylabel("level")
```

```

ax.set_xticklabels(ax.get_xticklabels(), rotation=30, ha="right")
ax.set_yticklabels(ax.get_yticklabels(), rotation=0)

plt.tight_layout()
plt.show()

```



1.5.4 Comptage empilé (stacked) : composition d'un champ au sein du Top Equipment

```

[37]: if "equipment" in df.columns and "level" in df.columns:
    df_stack = df.copy()
    df_stack["level_item"] = df_stack["level"].apply(safe_parse_list)
    df_stack = df_stack.explode("level_item")

    TOP_N = 4 # tu peux ajuster si besoin
    top_equipment = df_stack["equipment"].value_counts().head(TOP_N).index.
    tolist()
    top_levels = df_stack["level_item"].value_counts().head(4).index.tolist()

    df_stack = df_stack[
        df_stack["equipment"].isin(top_equipment)
        & df_stack["level_item"].isin(top_levels)
    ]

    stack_ct = pd.crosstab(df_stack["equipment"], df_stack["level_item"])
    display(stack_ct)

```

```

# --- Plot ---
ax = stack_ct.plot(
    kind="bar",
    stacked=True,
    figsize=(10, 5),      # + hauteur
    width=0.7            # barres plus épaisses
)

ax.set_title(
    "Répartition des niveaux (level) au sein du Top Equipment",
    pad=12
)

ax.set_xlabel("equipment")
ax.set_ylabel("Nombre de programmes")

ax.set_xticklabels(
    ax.get_xticklabels(),
    rotation=30,
    ha="right"
)

# Grille légère
ax.grid(True, axis="y", alpha=0.3)


# Légende propre
ax.legend(
    title="level",
    bbox_to_anchor=(1.02, 1),
    loc="upper left",
    frameon=False
)

plt.tight_layout()
plt.show()

else:
    print("Colonnes manquantes pour le stacked plot (equipment/level).")

```

level_item	Advanced	Beginner	Intermediate	Novice
equipment				
At Home	27	31	88	61
Dumbbell Only	14	20	48	36
Full Gym	604	550	1359	919
Garage Gym	203	136	418	267



1.5.5 Comptage empilé (stacked) : composition d'un champ au sein du Top Goal

```
[38]: if "equipment" in df.columns and "goal" in df.columns:
    df_stack = df.copy()
    df_stack["goal_item"] = df_stack["goal"].apply(safe_parse_list)
    df_stack = df_stack.explode("goal_item")

    TOP_N_EQUIP = 4
    TOP_N_GOAL = 5

    top_equipment = (
        df_stack["equipment"]
        .value_counts()
        .head(TOP_N_EQUIP)
        .index
        .tolist()
    )

    top_goals = (
        df_stack["goal_item"]
        .value_counts()
        .head(TOP_N_GOAL)
        .index
        .tolist()
    )

    df_stack = df_stack[
        df_stack["equipment"].isin(top_equipment)
        & df_stack["goal_item"].isin(top_goals)
```

```

]

stack_ct = pd.crosstab(df_stack["equipment"], df_stack["goal_item"])
display(stack_ct)

# --- Plot ---
ax = stack_ct.plot(
    kind="bar",
    stacked=True,
    figsize=(10, 5),    # + hauteur
    width=0.7           # barres épaisses
)

ax.set_title(
    "Répartition des objectifs (goal) au sein du Top Equipment",
    pad=12
)
ax.set_xlabel("equipment")
ax.set_ylabel("Nombre de programmes")

ax.set_xticklabels(
    ax.get_xticklabels(),
    rotation=30,
    ha="right"
)

ax.grid(True, axis="y", alpha=0.3)

ax.legend(
    title="goal",
    bbox_to_anchor=(1.02, 1),
    loc="upper left",
    frameon=False
)


plt.tight_layout()
plt.show()

else:
    print("Colonnes manquantes pour le stacked plot (equipment/goal).")

```

goal_item	Athletics	Bodybuilding	Muscle & Sculpting	Powerbuilding	
↳ Powerlifting					
equipment					
At Home	23	84	46	34	↳
↳ 16					
Dumbbell Only	13	41	19	21	↳
↳ 15					

Full Gym	384	1214	663	669	↵
↵ 355					
Garage Gym	118	384	207	181	↵
↵ 108					



```
[39]: stack_pct = stack_ct.div(stack_ct.sum(axis=1), axis=0)

ax = stack_pct.plot(
    kind="bar",
    stacked=True,
    figsize=(10, 5),
    width=0.7
)

ax.set_title(
    "Répartition relative des objectifs (goal) au sein du Top Equipment",
    pad=12
)

ax.set_ylabel("Proportion")
ax.set_xlabel("equipment")

ax.set_xticklabels(
    ax.get_xticklabels(),
    rotation=30,
    ha="right"
)

ax.legend(
    title="goal",
```

```

        bbox_to_anchor=(1.02, 1),
        loc="upper left",
        frameon=False
    )

    ax.grid(True, axis="y", alpha=0.3)
    plt.tight_layout()
    plt.show()

```

