

eda_top_50_excerices_for_your_body_v1.0

November 18, 2025

1 EDA – Gym Exercises Dataset

1.1 Objectif

Vérifier que le fichier `gym_exercises_dataset.csv` est correctement chargé et obtenir une vue d'ensemble :

- dimensions du jeu de données (nombre de lignes et de colonnes) ;
- typage des variables (champs textuels, listes de muscles, attributs techniques) ;
- premières observations sur les valeurs manquantes et la présence éventuelle de doublons ;
- cohérence générale du corpus avant analyse statistique et préparation NLP.

1.2 Interprétation attendue

À partir de cette première inspection, il s'agira de commenter :

- la taille globale du dataset (nombre de lignes / colonnes) ;
- la nature des variables (descriptifs textuels, attributs biomécaniques, catégories d'équipements) ;
- la présence éventuelle de valeurs manquantes ou de champs textuels incomplets ;
- l'existence (ou non) de doublons dans les données brutes ;
- la cohérence générale des premières lignes (valeurs lisibles, descriptions complètes, muscles cohérents).

Cette interprétation sert de point de départ pour juger de la qualité du corpus et préparer les étapes suivantes : nettoyage, normalisation textuelle et structuration pour le traitement NLP du projet TrAIn.me.

1.3 Configuration notebook

1.3.1 Importation des librairies essentielles

```
[2]: import os
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
import kagglehub
import prince

from pathlib import Path
```

```

import sys

from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA
from scipy import stats

# === Localiser automatiquement le package 'themes' en remontant l'arborescence
↳===
root = Path.cwd() # ex : .../train.me/src/notebooks/eda/health_fitness_dataset
themes_root = None

for p in [root, *root.parents]:
    if (p / "themes").is_dir():
        themes_root = p
        break

if themes_root is None:
    raise FileNotFoundError(
        f"Impossible de trouver le dossier 'themes' en partant de {root}. "
        "Vérifie l'arborescence : il doit exister un dossier 'themes/' quelque
↳part au-dessus."
    )

if str(themes_root) not in sys.path:
    sys.path.insert(0, str(themes_root))

print(" Ajouté au PYTHONPATH :", themes_root)
print(" Contenu de", themes_root, ":", [x.name for x in themes_root.iterdir()])

from themes.theme_train_me import set_trainme_theme

```

```

c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\.conda\Lib\site-
packages\tqdm\auto.py:21: TqdmWarning: IProgress not found. Please update
jupyter and ipywidgets. See
https://ipywidgets.readthedocs.io/en/stable/user_install.html
    from .autonotebook import tqdm as notebook_tqdm

Ajouté au PYTHONPATH :
c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks
Contenu de c:\Users\fbac\Desktop\Projets\Dev\GitHub\train.me\src\notebooks :
['eda', 'model_training', 'preprocessing', 'themes', '__init__.py']

```

Configuration d'affichage et thème TrAIIn.me

```

[3]: # Options d'affichage pour les tableaux
pd.set_option("display.max_columns", None)
pd.set_option("display.width", 120)

# =====

```

```
# Thème TrAIIn.me (Seaborn/Matplotlib)
# =====
USE_DARK_THEME = True # bascule possible vers un thème clair si besoin

palette_trainme = set_trainme_theme(
    context="talk",
    font_scale=1.05,
    use_dark=USE_DARK_THEME
)

palette_trainme
```

```
[3]: ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF', '#64D8FF']
```

1.3.2 Activation du thème TrAIIn.me

```
[4]: if USE_DARK_THEME:
    palette_trainme = set_trainme_theme(context="talk", font_scale=1.05,
    ↪ use_dark=True)
else:
    sns.set_style("ticks") # style clair sobre, axes renforcés
    sns.set_context("talk", font_scale=1.05)
    palette_trainme = sns.color_palette("deep") # palette par défaut sobre
    print(" Style activé : 'ticks' → sobre, axes renforcés (présentation pro)")

# Exemple de vérification :
print("Palette active :", palette_trainme.as_hex() if hasattr(palette_trainme,
    ↪ "as_hex") else palette_trainme)
```

```
Palette active : ['#00E5FF', '#00BFFF', '#0A84FF', '#1E90FF', '#00FFFF',
'#64D8FF']
```

1.3.3 3.4.1. Chargement et inspection initiale

Cette section vise à charger le fichier `gym_exercises_dataset.csv`, vérifier ses dimensions et obtenir un premier aperçu des données brutes. Elle reprend la même démarche que pour les autres EDA du projet : contrôle du chargement, visualisation des premières lignes, statistiques descriptives de base, analyse des valeurs manquantes et des doublons, puis liste complète des colonnes disponibles.

Chargement du dataset `gym_exercises_dataset.csv`

```
[5]: # Téléchargement du dataset depuis Kaggle
dataset_path = kagglehub.dataset_download("prajwaldongre/
    ↪ best-50-exercise-for-your-body")

# Recherche du fichier CSV dans le dossier téléchargé
csv_files = [f for f in os.listdir(dataset_path) if f.endswith(".csv")]
print("Fichiers trouvés :", csv_files)
```

```
# Construction du chemin complet vers le CSV
file_path = os.path.join(dataset_path, csv_files[0])

# Lecture du fichier CSV
df = pd.read_csv(file_path)

# Informations de confirmation
print("Dataset chargé avec succès !")
print(f"Dimensions : {df.shape[0]} lignes et {df.shape[1]} colonnes\n")
```

Downloading from
https://www.kaggle.com/api/v1/datasets/download/prajwaldongre/best-50-exercise-for-your-body?dataset_version_number=1...
 100%| | 1.76k/1.76k [00:00<00:00, 1.80MB/s]
 Extracting files...
 Fichiers trouvés : ['Top 50 Excerice for your body.csv']
 Dataset chargé avec succès !
 Dimensions : 50 lignes et 8 colonnes

Aperçu des premières lignes

```
[6]: df.head(10)
```

```
[6]:
```

	Name of Exercise	Sets	Reps	
Benefit	Burns Calories (per 30 min)			\
0	Push-ups	3	15	Builds upper body
strength			200	
1	Squats	4	12	Strengthens lower
body			223	
2	Lunges	3	10	Improves balance and
coordination			275	
3	Burpees	3	10	Full body
workout			355	
4	Mountain Climbers	3	20	Improves cardiovascular
fitness			240	
5	Jumping Jacks	3	30	Improves coordination and cardiovascular
health			295	
6	Bicycle Crunches	3	20	Targets abdominal
muscles			210	
7	Dips	3	12	Strengthens triceps and
chest			180	
8	Pull-ups	3	8	Builds upper body
strength			250	
9	Russian Twists	3	20	Improves core rotation

strength

190

	Target Muscle Group	Equipment Needed	Difficulty Level
0	Chest, Triceps, Shoulders	NaN	Intermediate
1	Quadriceps, Hamstrings, Glutes	NaN	Beginner
2	Quadriceps, Hamstrings, Glutes	NaN	Beginner
3	Full Body	NaN	Advanced
4	Core, Shoulders, Legs	NaN	Intermediate
5	Full Body	NaN	Beginner
6	Core	NaN	Intermediate
7	Triceps, Chest	Parallel Bars or Chair	Intermediate
8	Back, Biceps	Pull-up Bar	Advanced
9	Core, Obliques	None or Dumbbell	Intermediate

Informations sur le typage, les valeurs manquantes et les doublons

```
[7]: # Typage et complétude globale
df_info = df.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50 entries, 0 to 49
Data columns (total 8 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Name of Exercise                      50 non-null     object
1   Sets                                  50 non-null     int64
2   Reps                                  50 non-null     int64
3   Benefit                               50 non-null     object
4   Burns Calories (per 30 min)          50 non-null     int64
5   Target Muscle Group                  50 non-null     object
6   Equipment Needed                     30 non-null     object
7   Difficulty Level                     50 non-null     object
dtypes: int64(3), object(5)
memory usage: 3.3+ KB
```

1.3.4 Statistiques descriptives des variables numériques

```
[8]: display(df.describe().T)
```

	count	mean	std	min	25%	50%	75%	max
Sets	50.0	3.12	0.328261	3.0	3.0	3.0	3.0	3.0
Reps	50.0	12.78	4.559314	5.0	10.0	12.0	15.0	30.0
Burns Calories (per 30 min)	50.0	229.96	58.896991	130.0	180.0	221.5	278.0	355.0

1.3.5 Analyse des valeurs manquantes et doublons

```
[9]: # Comptage des valeurs manquantes par colonne
missing_counts = df.isna().sum().sort_values(ascending=False)

print("\n Valeurs manquantes par colonne (top 20) :")
display(missing_counts.head(20))

# Comptage des doublons ligne à ligne
n_duplicates = df.duplicated().sum()
print(f"\n Nombre de doublons (lignes strictement identiques) : \n
↳ {n_duplicates}")
```

Valeurs manquantes par colonne (top 20) :

Equipment Needed	20
Name of Exercise	0
Sets	0
Reps	0
Benefit	0
Burns Calories (per 30 min)	0
Target Muscle Group	0
Difficulty Level	0

dtype: int64

Nombre de doublons (lignes strictement identiques) : 0

Liste complète des colonnes disponibles

```
[10]: print("\n--- Liste des colonnes du dataset ---")
print(df.columns.tolist())
```

--- Liste des colonnes du dataset ---

```
['Name of Exercise', 'Sets', 'Reps', 'Benefit', 'Burns Calories (per 30 min)',
'Target Muscle Group', 'Equipment Needed', 'Difficulty Level']
```